

Árboles de decisión y CART



De reglas interpretables a modelos no lineales para decidir

CART

Gini · Entropía


Pruning

Interpretabilidad



Del modelo lineal a reglas de decisión

El módulo anterior produjo probabilidades; ahora aprenderemos modelos que segmentan el espacio mediante preguntas.



Idea central: un árbol aprende una secuencia de preguntas simples que divide datos heterogéneos en grupos más homogéneos.

Riesgo central: esa flexibilidad puede memorizar el entrenamiento si no controlamos complejidad y validación.

Continuidad con logística

Probabilidad estimada $\neq$ decisión operativa.
La métrica se interpreta con costos, umbrales y capacidad.
El test no participa de diseño ni poda.

Nuevo foco

Reglas, interacciones y no linealidad sin especificarlas a mano.
Control de varianza mediante poda y validación.
Puente natural hacia Random Forest.

Pregunta de decisión

La clase no termina en un árbol bonito: termina en una regla defendible para actuar.

¿Qué reglas e interacciones segmentan el problema y qué tan confiables son fuera de muestra?

01

Entender

cómo un árbol elige splits con Gini o entropía.

02

Construir

un árbol de clasificación/regresión paso a paso.

03

Controlar

overfitting con profundidad, hojas mínimas y pruning.

04

Traducir

hojas a reglas IF-THEN con límites claros.

05

Preparar


el puente hacia bagging y Random Forest.

Caso guía: priorización de siniestros

Una aseguradora quiere revisar casos con mayor riesgo sin saturar al equipo de auditoría.

Entrada

Monto reclamado
Antigüedad del asegurado
Tipo de cobertura
Historial de siniestros
Canal de denuncia



Salida


Ranking de casos
Reglas justificables
Capacidad diaria
Control de falsos positivos
Revisión periódica

El objetivo no es maximizar exactitud en abstracto: es decidir a quién revisar, con qué costo y bajo qué límite de capacidad.

Cuando una frontera lineal no alcanza


Los árboles agregan valor cuando la decisión depende de umbrales, segmentos o interacciones.

Frontera lineal



Un único plano separador obliga a resumir el patrón.


Partición por reglas



Las reglas generan regiones rectangulares y capturan interacciones.

Un árbol traduce datos en preguntas encadenadas

Cada nodo formula una pregunta binaria; cada respuesta reduce heterogeneidad.



Lectura como reglas

Si $\text{monto} > 1\text{M}$ y $\text{historial} > 2 \rightarrow$ revisión alta.
Si $\text{monto} > 1\text{M}$ e $\text{historial} \leq 2 \rightarrow$ revisión media.
Si $\text{monto} \leq 1\text{M} \rightarrow$ revisión baja.

La interpretabilidad surge porque el camino raíz $\rightarrow$ hoja puede explicarse como una regla operacional.

Anatomía de un árbol

Nombre cada pieza antes de discutir matemática, complejidad o interpretación.

Nodo raíz

conjunto completo de observaciones

Rama

resultado de una pregunta

Nodo interno


subconjunto que vuelve a dividirse

Hoja

nodo terminal que predice



Profundidad

máximo número de decisiones encadenadas



Dos representaciones de un mismo modelo

El árbol y la partición 2D dicen lo mismo con lenguajes diferentes.



Un split vertical en el plano es una pregunta sobre x_1 . Un split horizontal posterior es una pregunta sobre x_2 solo dentro de una región.

CART: Classification and Regression Trees

Una receta greedy: elegir el mejor split local, repetir, detener y eventualmente podar.

1

Elegir variable y umbral candidato

2

Medir impureza antes y después

3

Conservar el split con mayor reducción

4

Repetir recursivamente en cada hijo

5

Detener por regla de complejidad

6


Podar si mejora validación

$$\text{split}^* = \operatorname{argmin} \text{ impureza ponderada de los hijos}$$

El algoritmo no prueba “todas las teorías”: prueba candidatos de división y elige el mejor localmente.

¿Qué significa “buen split”?

No buscamos dividir por dividir: buscamos hijos más homogéneos que el padre.



Un buen split reduce mezcla dentro de los hijos, ponderando por cuántas observaciones caen en cada lado.

$$\text{Ganancia} = I(\text{padre}) - [nL/n \cdot I(L) + nR/n \cdot I(R)]$$

I puede ser Gini, entropía u otra función de impureza.

Impureza Gini

Gini mide cuán mezcladas están las clases dentro de un nodo.

$$\text{Gini}(t) = 1 - \sum_k p_k^2$$

p_k es la proporción de observaciones de la clase k dentro del nodo.

Tres situaciones

Nodo puro



Gini = 0

50 / 50



Gini = 0,50

80 / 20



Gini = 0,32

Lectura rápida: Gini baja cuando una clase domina. Un split útil busca hijos con Gini menor que el padre.

Ejemplo calculado: dos splits candidatos

El algoritmo compara impureza ponderada, no intuiciones visuales.

Nodo padre: 100 casos · 50 positivos · 50 negativos

$$\text{Gini(padre)} = 1 - 0,5^2 - 0,5^2 = 0,50$$

Split A

Izq: 40+ / 10-



Der: 10+ / 40-



Imp. ponderada = 0,32

Split B

Izq: 30+ / 20-



Der: 20+ / 30-



Imp. ponderada = 0,48

Split A gana porque produce hijos más puros: reducción de impureza = $0,50 - 0,32 = 0,18$.

Entropía e information gain

Otra forma de medir incertidumbre: muy útil para conectar con teoría de información.

$$H(t) = - \sum_k p_k \log_2(p_k)$$

Entropía alta: mezcla intensa. Entropía cero: nodo puro.

$$IG = H(\text{padre}) - H \text{ ponderada}(\text{hijos})$$

Information Gain mide cuánto reduce incertidumbre el split.


Máxima mezcla → máxima entropía



Para dos clases, la curva sube hasta $p=0,5$ y baja cuando una clase domina.

Gini vs entropía

En la práctica suelen elegir splits similares, pero no enseñan exactamente lo mismo.





Gini es rápido, simple y muy usado en CART.
Entropía penaliza con más fuerza ciertas mezclas extremas.
La comparación importante no es “cuál es mejor” sino mantener validación coherente.

Regla docente: usá Gini para construir intuición operativa; mostrale al alumno que entropía cuenta una historia de incertidumbre.

Construcción recursiva paso a paso

Cada hoja candidata se convierte en un nuevo problema de split.



El árbol es greedy: una decisión local temprana condiciona todo lo que viene después.

¿Qué predice una hoja?

La hoja resume las observaciones que llegaron por el mismo camino.

Hoja con 40 casos
28 positivos · 12 negativos

$$P(y=1 \mid \text{hoja}) = 28 / 40 = 0,70$$

Clasificación: la clase mayoritaria o probabilidad estimada.

$$\hat{y} = \text{promedio}(y \text{ en hoja})$$

Regresión: la predicción suele ser la media de la respuesta en esa hoja.

Advertencia: las probabilidades de árboles profundos pueden ser extremas y mal calibradas si las hojas tienen pocos casos.

Árboles de regresión

No todos los árboles clasifican: también predicen valores continuos.

Ejemplo: estimar monto esperado de siniestro




Split = menor error cuadrático ponderado

En regresión, los splits buscan reducir variabilidad de y dentro de las hojas.

La predicción de cada hoja es un promedio local.
La frontera sigue siendo por umbrales.
Puede aproximar relaciones no lineales por tramos.

Interacciones sin escribir interacciones

Un árbol puede condicionar una variable según el valor de otra.



Regla aprendida

Primero dividir por x_1 .


Solo si x_1 es alto, preguntar por x_2 .

El efecto de x_2 existe dentro de un segmento, no globalmente.

Esto equivale a una interacción: la importancia de una variable depende de otra condición previa.

Interpretabilidad: reglas IF-THEN

El árbol no solo predice: también puede generar reglas auditables.



Regla 1

IF edad > 45 AND monto > 1M THEN revisión alta

Regla 2

IF edad > 45 AND monto ≤ 1M THEN revisión media

Regla 3

IF edad ≤ 45 THEN revisión baja

Las reglas son explicables, pero solo son defendibles si fueron validadas fuera de muestra.

Complejidad: cuánto crece el árbol

Más profundidad significa más segmentos, más memoria y más riesgo de sobreajuste.

prof. 1



≤ 2 hojas

prof. 2



≤ 4 hojas

prof. 3



≤ 8 hojas

prof. 4



≤ 16 hojas

prof. 5




≤ 32 hojas

Hojas máximas $\leq 2^{\text{profundidad}}$

El crecimiento puede ser explosivo incluso con pocas variables.

Overfitting: el árbol memoriza regiones pequeñas

La señal de alerta no está en train score, sino en la brecha con validación.



El mejor árbol no es el más profundo; es el que maximiza desempeño validado con complejidad razonable.

Hiperparámetros que controlan el árbol

Cada control limita una forma distinta de complejidad.

max_depth

cantidad máxima de decisiones encadenadas

min_samples_split

mínimo para volver a dividir un nodo

min_samples_leaf

mínimo de observaciones por hoja

max_leaf_nodes

número máximo de hojas

criterion

Gini, entropía o error cuadrático


ccp_alpha

penalización de poda costo-complejidad


Regla práctica: ajustar complejidad con validación; no elegir hiperparámetros mirando el test.

max_depth: el control más visible

Limita cuántas preguntas puede encadenar el árbol.



Baja profundidad



Alta profundidad

min_samples_leaf y min_samples_split

Evitan reglas basadas en grupos demasiado pequeños.

Hoja con 2 casos
100% positivos

Parece perfecta, pero puede ser ruido.

Hoja con 60 casos
72% positivos

Menos extrema, más estable.

La interpretabilidad no mejora si cada regla se apoya en muy pocas observaciones.

Pre-pruning: detener antes de memorizar

Se define una complejidad máxima antes o durante el entrenamiento.



No hay atajos: si elegís profundidad mirando el test, contaminás la evidencia final.

Post-pruning: poda costo-complejidad

Primero crece el árbol; luego se penaliza el número de hojas.

$$R\alpha(T) = R(T) + \alpha \cdot |T|$$

$R(T)$: error del árbol. $|T|$: cantidad de hojas. α : penalización por complejidad.

Interpretación de α

α pequeño: tolera árboles más grandes.
 α grande: favorece árboles más simples.
Se elige con validación, no por estética.



El camino de poda

A medida que aumenta α , desaparecen ramas completas.

α 0



16 hojas

α bajo



10 hojas

α medio



5 hojas

α alto



2 hojas

La poda convierte un árbol sobreajustado en una familia de modelos candidatos; la validación decide.

Sesgo-varianza en árboles

La profundidad reduce sesgo, pero puede aumentar mucho la varianza.



El “punto dulce” no está en máxima complejidad sino donde el error esperado fuera de muestra se minimiza.

Inestabilidad: el talón de Aquiles del árbol

Pequeñas perturbaciones de datos pueden cambiar la estructura del árbol.



Esta inestabilidad prepara la necesidad de bagging: entrenar muchos árboles y promediar decisiones.

Probabilidades de árboles: cuidado con calibración

Un árbol profundo puede producir probabilidades 0 o 1 aunque la incertidumbre real sea alta.

Hoja pequeña
3 positivos · 0 negativos
 $\hat{P} = 1,00$

Hoja amplia
70 positivos · 30 negativos
 $\hat{P} = 0,70$

Para tomar decisiones con costos, no alcanza la clase predicha: importan ranking, calibración y umbral.

Desbalance de clases y costos asimétricos

En siniestros, fraude o riesgo, el error raro puede ser el más caro.

Matriz de confusión operativa

TN Correcto bajo	FP Revisión innecesaria
FN Riesgo omitido	TP Correcto alto


Lectura de negocio

Falso positivo: revisar un caso innecesario.
Falso negativo: dejar pasar un caso riesgoso.
El umbral se define con costo, capacidad y prevalencia.

Un árbol puede ser interpretado, pero el umbral y la política siguen siendo decisiones de negocio.

Métrica técnica + política de decisión

La métrica ordena modelos; la política define qué se hace con la predicción.



Ejemplo de cierre del análisis

AUC valida capacidad de ranking.
Precision@K valida capacidad de auditoría diaria.
Costo esperado valida valor económico.
Reglas extraídas validan comunicación operativa.

$$\text{Valor} = \text{TP} \cdot \text{beneficio} - \text{FP} \cdot \text{costo} - \text{FN} \cdot \text{pérdida}$$

El mejor árbol es el que sostiene una acción, no el que maximiza una métrica aislada.

Importancia de variables: útil pero peligrosa

La importancia interna explica uso predictivo dentro del modelo, no causalidad.



Una variable puede ser importante porque aparece temprano en splits.
Variables correlacionadas pueden repartirse o esconder importancia.
Permutation importance fuera de muestra es más defendible.
Interpretación predictiva $\neq$ efecto causal.

Este tema se profundiza en PPT 03, pero la advertencia debe quedar desde ahora.

Clasificación vs regresión: misma estructura, distinta pérdida

El árbol sigue preguntando por umbrales; cambia la función que evalúa el split.

Clasificación



Split: reduce Gini/entropía

Regresión



Split: reduce varianza / MSE

Flujo de trabajo para el caso de siniestros

Cómo transformar el árbol en evidencia para decidir.

- 1 Definir acción** revisar / no revisar
- 2 Entrenar árbol simple** validar profundidad y hojas
- 3 Medir costos** FP, FN y capacidad
- 4 Traducir reglas** explicar segmentos críticos
- 5 Revisar estabilidad** nueva muestra / período

El entregable no es el árbol aislado: es una recomendación trazable, con evidencia fuera de muestra y límites operativos.

Laboratorio de la clase

El objetivo práctico es ver el árbol, controlar su complejidad y defender una regla.

A

Árbol pequeño

visualizar y leer caminos raíz
→ hoja

B

Gini manual

calcular impureza de splits
candidatos

C

Complejidad

probar `max_depth` y
`min_samples_leaf`

D

Poda

seleccionar `ccp_alpha` con
validación

E

Reglas

`export_text` y recomendación
de negocio

Criterio de éxito: el árbol debe sostener una decisión, superar una referencia y declarar límites.

Laboratorio de árboles: simulaciones 01-06

Cada simulación conecta el concepto con una hipótesis y evidencia.

01 Split y Gini

02 Gini vs entropía

03 Árbol ↔ partición 2D

04 Profundidad y overfitting

05 Poda ccp_alpha

06 Inestabilidad

Recorrido de estudio: presentación, simulación, práctica en Python y decisión fundamentada.

Checklist de un árbol defendible

Antes de presentar el resultado, verificá cinco condiciones.

- ✓ La pregunta de decisión está explicitada.
- ✓ El criterio de split se entiende y se puede explicar.
- ✓ La complejidad fue elegida por validación.
- ✓ Las reglas no dependen de hojas diminutas.
- ✓ La recomendación incluye costos, límites y revisión.

Errores frecuentes

La mayoría de los problemas no son de sintaxis: son de diseño de evidencia.

✗ **Árbol demasiado profundo**

score perfecto en train, pobre fuera de muestra

✗ **Hojas muy pequeñas**

reglas extremas con poca evidencia

✗ **Test usado para elegir modelo**

contaminación de evaluación final

✗ **Importancia = causalidad**

interpretación predictiva mal usada


✗ **Métrica sin decisión**

resultado técnico sin acción

Un árbol interpretable pero mal validado no es evidencia: es una historia convincente sin prueba.

Puente hacia Random Forest

Si un árbol es flexible e inestable, la pregunta natural es combinar muchos árboles.



PPT 02: bootstrap, bagging, Random Forest, OOB error y decorrelación entre árboles.

Árboles: reglas, generalización y decisiones

Construye particiones mediante preguntas binarias.
El split se elige por reducción de impureza.
La complejidad sin control produce overfitting.
La poda convierte flexibilidad en evidencia defendible.
La inestabilidad abre la puerta a Random Forest.

Próximo paso: PPT 02 · Bagging y Random Forest