


Bagging y Random Forest

De un árbol inestable a un conjunto robusto de modelos

El bosque combina árboles diversos para reducir varianza y estabilizar predicciones.

- Bootstrap: cada árbol ve una muestra distinta
- Random subspace: cada split mira variables distintas
- Voto/promedio: el conjunto estabiliza la decisión



La historia del módulo

El objetivo no es “usar Random Forest”, sino entender qué problema resuelve, cuándo aporta valor y qué errores puede ocultar.

01

Árbol único

flexible, interpretable,
inestable

02

Bagging

promediar modelos de alta
varianza

03

Random Forest

decorrelacionar árboles

04

Evaluar

OOB, validación, estabilidad

05

Decidir


valor, latencia e
interpretación

Pregunta de decisión

¿Cuánto mejora la decisión al combinar muchos modelos, y qué costo paga la organización por esa mejora?

Recordatorio: un árbol aprende reglas locales

Un árbol divide el espacio con preguntas simples. Eso lo vuelve claro, pero también sensible a pequeñas variaciones de los datos.



Problema




- Alta varianza: el árbol puede cambiar mucho si cambia poco el set de entrenamiento.
- La frontera rectangular puede memorizar ruido si crece sin control.
- La interpretación es fuerte, pero la predicción puede ser frágil.

Intuición

Alta flexibilidad + pocos datos $\Rightarrow$ varianza

La inestabilidad es el puente hacia ensembles

Entrenar dos árboles con muestras levemente distintas puede producir reglas distintas. El patrón puede ser real, pero la regla particular puede no ser estable.



La solución no es hacer un árbol más grande; es reducir varianza combinando árboles diversos.

Ensemble: muchas miradas parciales, una decisión más estable

Cada árbol ve una versión imperfecta del problema. El conjunto aprovecha que los errores no son exactamente iguales.



Bootstrap: entrenar árboles sobre muestras re-muestreadas

Cada árbol se entrena con una muestra del mismo tamaño que la original, obtenida con reemplazo. Algunas observaciones se repiten; otras quedan fuera.



principio

muestra con reemplazo → árboles diferentes

OOB: la validación que nace del bootstrap

Una observación tiene una probabilidad cercana al 36,8% de no aparecer en la muestra bootstrap de un árbol. Ese árbol puede usarse para evaluar esa observación.

resultado clave

$$P(\text{no seleccionada}) = (1 - 1/n)^n \rightarrow e^{-1} \approx 0,368$$

$\approx 36,8\%$

queda out-of-bag para cada árbol

- El OOB score permite una estimación interna de desempeño.
- No reemplaza siempre a un test final, pero es muy útil para diagnóstico.
- Funciona porque cada observación es evaluada por árboles que no la entrenaron.

Idea operativa

Para cada caso, juntamos los votos de los árboles donde ese caso fue OOB.

Bagging = Bootstrap Aggregating

El bagging no busca un árbol perfecto: construye muchos árboles fuertes e inestables y reduce su varianza al agregarlos.

1. Para $b = 1, \dots, B$
2. Tomar bootstrap del entrenamiento
3. Ajustar un árbol profundo T_b
4. Clasificación: agregar predicciones
5. Regresión: promediar

regresión

$$\hat{f}_{\text{bag}}(x) = (1/B) \sum_b T_b(x)$$


clasificación

$$\hat{p}(k|x) = \text{promedio}_b \hat{p}_b(k|x)$$

Bagging suele mejorar la estabilidad sin cambiar demasiado el sesgo del árbol base.

Qué cambia y qué no cambia al promediar

Promediar modelos diversos reduce varianza. Si todos comparten el mismo sesgo, el promedio no lo elimina.



principio

$\text{Var}(\text{promedio})$ baja si los errores no son perfectamente iguales

Muchos árboles no alcanzan si son demasiado parecidos

La reducción de varianza depende de la cantidad de árboles y de la correlación entre ellos. Random Forest ataca directamente esa correlación.

aproximación

$$\text{Var}(\bar{f}) \approx \rho\sigma^2 + [(1-\rho)/B]\sigma^2$$

Cuando B crece, desaparece la segunda parte;
queda $\rho\sigma^2$.

B ↑

muchos árboles

ρ ↓

correlación

↓


varianza final

max_features

Random Forest

Random Forest agrega aleatoriedad en las variables

En cada split, el árbol no puede mirar todas las variables: solo un subconjunto aleatorio. Eso fuerza árboles menos correlacionados.



En cada nodo

- se sortean variables candidatas
- se busca el mejor split solo dentro de ese subconjunto
- el árbol pierde algo de fuerza individual pero gana diversidad

definición práctica

Random Forest = Bagging + selección aleatoria de variables en cada split

Construcción de un Random Forest

El bosque combina muestreo de filas, muestreo de variables y agregación. Esa combinación es la fuente de su robustez.

1

Bootstrap

muestra filas con reemplazo

2

Árbol

repite preguntas en cada
nodo

3

Variables

cada split ve pocas variables

4

Agregación


voto o promedio final

salida del modelo

Para clasificar: promediar probabilidades de los árboles y elegir la clase con mayor valor.


De frontera fragmentada a decisión estabilizada

Un árbol puede generar cortes muy abruptos. Bagging suaviza por agregación; Random Forest agrega diversidad de variables y reduce correlación.




Árbol único

alta varianza



Bagging

promedio de árboles




Random Forest

promedio + decorrelación

La mejora no se “ve” solo como una frontera más linda: se valida con datos fuera de muestra y con una decisión concreta.

n_estimators: más árboles estabilizan, no hacen magia

Aumentar B reduce variabilidad hasta un punto. El costo computacional crece, y el error puede estabilizarse antes de valores muy altos.



Lectura

- Pocos árboles: predicción inestable.
- Muchos árboles: menor variabilidad, pero más tiempo.
- Cuando la curva se aplana, seguir agregando árboles puede no cambiar la decisión.

n_estimators

control clave

max_features: fuerza individual versus diversidad

Si cada split mira muchas variables, los árboles se parecen más. Si mira muy pocas, ganan diversidad pero cada árbol puede debilitarse.

max_features alto

- árboles fuertes
- menor aleatoriedad
- mayor correlación

max_features medio

- balance habitual
- reduce correlación
- mantiene señal

max_features bajo

- alta diversidad
- árboles más débiles
- puede perder señal

criterio

La pregunta práctica: ¿qué combinación maximiza desempeño estable fuera de muestra?

Complejidad del árbol base: profundidad y tamaño de hoja

Random Forest tolera árboles profundos, pero no elimina la necesidad de controlar ruido, hojas minúsculas y restricciones operativas.

profundidad

`max_depth`

tamaño mínimo

`min_samples_leaf`

cuándo dividir

`min_samples_split`

hojas máximas

`max_leaf_nodes`

Regla práctica: ajustar complejidad del árbol base después de fijar una validación coherente; no optimizar hiperparámetros mirando el test final.


bootstrap y max_samples: cuánto ve cada árbol

No siempre conviene que cada árbol use una muestra bootstrap completa. Reducir max_samples puede aumentar diversidad y bajar costo, pero también debilitar árboles.

Árbol más débil, menos correlación



Árbol más fuerte, más correlación



Lectura

max_samples permite controlar diversidad y costo cuando el dataset es grande.

criterio

Diversidad útil $\neq$ aleatoriedad sin señal

OOB score como diagnóstico, no como excusa

El OOB score permite evaluar durante el entrenamiento, pero el proyecto debe preservar validación y test según la decisión.



Error frecuente: usar OOB para ajustar todo y luego reportarlo como desempeño final sin test independiente.

Random Forest sirve para clasificación y regresión

La lógica del bosque se mantiene; cambia la predicción de cada hoja y la función de error usada para evaluar.

Clasificación

- cada árbol vota clase o probabilidad
- salida: mayoría o promedio de probabilidades
- métricas: ROC-AUC, PR-AUC, recall, precisión, costo

Regresión

- cada árbol predice una media de hoja
- salida: promedio de predicciones
- métricas: MAE, RMSE, error por segmento, costo

regla

La salida debe evaluarse según la decisión, no solo según el tipo de modelo.

Comparar modelos exige mirar más que AUC

Un bosque con mejor ranking puede ser peor decisión si falla calibración, latencia, costo de falso positivo o estabilidad por segmento.

Discriminación

ROC-AUC · PR-AUC

Calibración

Brier · reliability

Costo

FP · FN · capacidad

Operación

fit · predict · memoria

criterio

El modelo ganador es el que mejora la decisión bajo restricciones reales.

Mean Decrease Impurity: rápido, útil y peligroso

La importancia interna de Random Forest mide cuánto redujeron impureza los splits de una variable. No mide causalidad ni valor de negocio.



Cuidado

- favorece variables con muchos puntos de corte
- puede repartir importancia de forma engañosa
- no es un efecto causal
- debe calcularse dentro de un diseño de validación

Permutation importance: medir pérdida de desempeño

La pregunta cambia: ¿cuánto empeora el modelo cuando rompo la relación entre una variable y la respuesta fuera de muestra?

1. Modelo fijo

entrenado previamente

2. Permutar X_j

romper una variable

3. Medir caída

pérdida de métrica

definición operativa

$$\text{Importancia}_j = \text{score_original} - \text{score_con_X}_j\text{permutada}$$

Variables correlacionadas: cuando la importancia engaña

Si dos variables transportan información muy parecida, permutar una puede no afectar mucho porque la otra la reemplaza parcialmente.

Variable A

score_credificio

Variable B

rating_bureau

Modelo

**usa ambas como
sustitutos parciales**

regla de lectura

Baja importancia individual no implica irrelevancia informativa.

Random Forest produce scores; la decisión requiere umbral

La clase predicha no basta. En problemas de negocio importan probabilidad, calibración, costo y capacidad.




recordatorio

Probabilidad estimada $\neq$ acción automática

Caso: priorizar siniestros para revisión

El bosque puede detectar patrones no lineales e interacciones, pero la política debe respetar capacidad, costo y trazabilidad.



El umbral debe dialogar con la capacidad operativa

Un modelo que selecciona demasiados casos puede ser inútil si el equipo no puede revisarlos.

10.000

casos diarios (ejemplo)

350

capacidad revisión

3,5%

top seleccionado

**tiempo +
fricción**

costo FP

La política puede ser “revisar los 350 casos con mayor score”, no necesariamente “predecir positivo si $p > 0,5$ ”.

Más árboles también significan costo operacional

Random Forest suele ser robusto, pero puede ser pesado en memoria y predicción si se lo escala sin restricciones.

Entrenamiento

fit time

Predicción

latencia

Memoria

tamaño modelo

Monitoreo

drift por segmento

criterio

Desempeño técnico sin viabilidad operativa no mejora la decisión.

Workflow mínimo en scikit-learn

El notebook del módulo debe comparar modelos con el mismo protocolo y registrar evidencia reproducible.

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import cross_validate, StratifiedKFold

rf = RandomForestClassifier(
    n_estimators=500, max_features="sqrt",
    min_samples_leaf=20, oob_score=True,
    n_jobs=-1, random_state=42
)
cv = StratifiedKFold(5, shuffle=True, random_state=42)
```

Este código es punto de partida, no receta universal: hiperparámetros y métricas dependen del costo de decisión.

Errores frecuentes que invalidan el análisis

Random Forest es fácil de correr y fácil de malinterpretar.

1. Comparar modelos con splits distintos.

2. Reportar OOB como desempeño final sin test.

3. Interpretar feature importance como causalidad.

4. Optimizar hiperparámetros mirando el test.

5. Ignorar calibración y costos.

6. Agregar árboles sin medir latencia ni memoria.

Laboratorio guiado: del árbol al bosque

La práctica debe forzar comparación honesta y registro de decisión, no solo ejecutar RandomForestClassifier.

- 1. Entrenar árbol podado y traducir reglas
- 2. Medir inestabilidad con bootstrap
- 3. Entrenar bagging y Random Forest
- 4. Comparar OOB, CV y test
- 5. Medir importancia por permutación
- 6. Decidir política bajo capacidad y costo

Entregable

**Tabla comparativa + explicación
validada + recomendación operativa.**

Benchmark esperado del módulo

Cada modelo debe compararse con las mismas particiones, métricas y restricciones.

Modelo	ROC-AUC	PR-AUC	Brier	FP/FN	ms
Logística	—	—	—	—	—
Árbol podado	—	—	—	—	—
Random Forest	—	—	—	—	—
Boosting	—	—	—	—	—

regla

Sin benchmark común no hay conclusión defendible.

Interpretabilidad, estabilidad y desempeño

Random Forest ocupa un punto intermedio: menos interpretable que un árbol, más estable; más transparente que muchos modelos complejos, pero no automáticamente explicable.

Árbol	Interpretabilidad: alto	Estabilidad: baja	Desempeño: media
Random Forest	Interpretabilidad: media	Estabilidad: alta	Desempeño: alta
Boosting	Interpretabilidad: media-baja	Estabilidad: alta	Desempeño: alta
Logística	Interpretabilidad: alta	Estabilidad: media	Desempeño: media

La tabla no es una verdad universal: resume tendencias que deben validarse en cada problema.

Cuándo Random Forest puede no ser la mejor opción

Un buen modelo no es solo el que predice bien; también debe integrarse en el proceso de decisión.

- Si se necesita una regla simple y auditable, un árbol podado puede ser preferible.
- Si la relación es casi lineal y la muestra es pequeña, logística puede competir muy bien.
- Si se exige extrapolación fuera del rango observado, los árboles tienen límites fuertes.
- Si la latencia es crítica, un bosque enorme puede ser inviable.
- Si la pregunta es causal, Random Forest predictivo no alcanza por sí solo.

El modelo correcto es el que mejora una decisión concreta bajo restricciones reales.

Próximo paso: Boosting

Random Forest entrena árboles en paralelo y promedia. Boosting entrena árboles secuencialmente, intentando corregir errores previos.

Random Forest

- árboles paralelos
- reduce varianza
- agregación por voto/promedio
- robusto y estable

Boosting

- árboles secuenciales
- corrige errores
- learning rate
- puede lograr alto desempeño

transición

Bagging pregunta: ¿cómo estabilizo modelos inestables? Boosting pregunta: ¿cómo corrijo errores paso a paso?

Tres ideas que deben quedar claras

1

Random Forest no es un árbol grande

es una estrategia de diversidad + agregación

2

La clave no es solo B

también importa la correlación entre árboles

3

La importancia no es causalidad

la explicación debe validarse fuera de muestra

Próximo módulo: Boosting, interpretación avanzada y decisión bajo costos.

Preguntas para abrir la práctica

Estas preguntas conectan la teoría con el notebook y las simulaciones.

- ¿Qué métrica usarías si los positivos son raros y costosos?
- ¿Cuándo preferirías árbol podado antes que Random Forest?
- ¿Cómo detectarías que la importancia de variables está engañando?
- ¿Qué umbral usarías si solo podés revisar 350 casos por día?
- ¿Qué evidencia exigirías antes de poner el modelo en producción?

La respuesta correcta no es “más árboles”: es mejor evidencia para una decisión concreta.