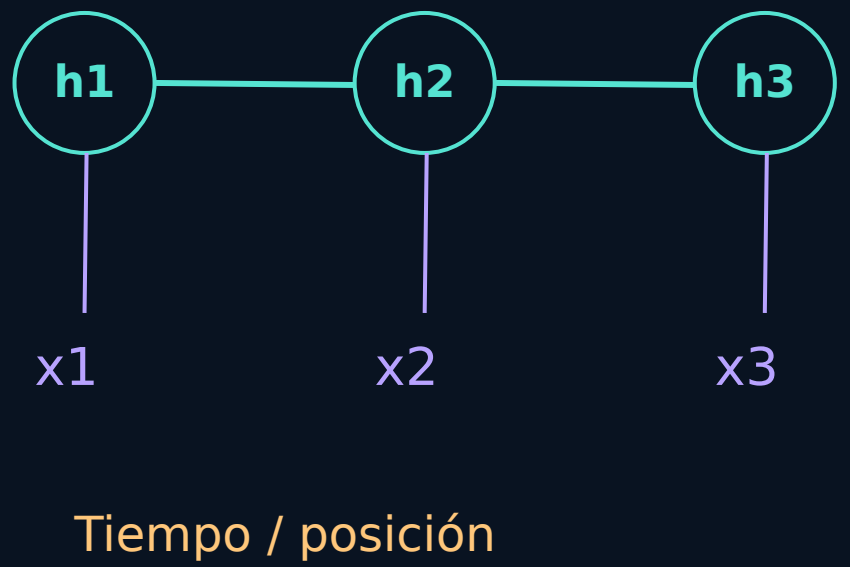
Secuencias, RNN y LSTM

Ampliación de Ciencias de Datos II · UCA

Memoria, gradientes y predicción temporal

Sergio Gevatschnaider



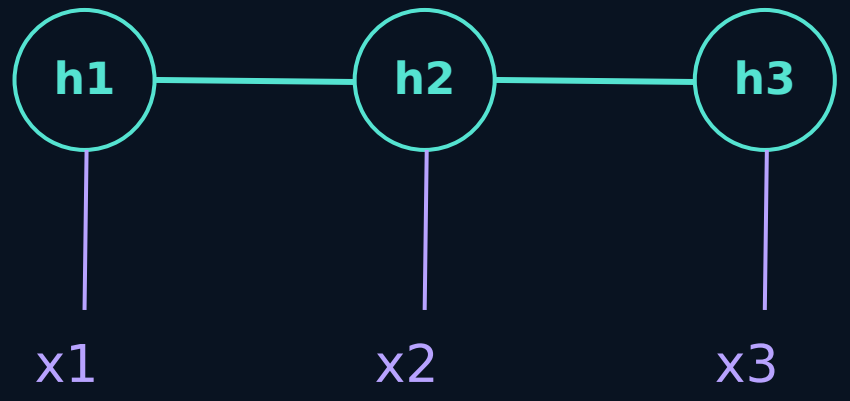
El orden puede contener información

Tabular: atributos de una unidad

Secuencial: observaciones indexadas por tiempo o posición

Ejemplo: misma venta actual, historial creciente o decreciente

Mismos pesos en cada paso



Tiempo / posición

¿Podemos modelar una serie con un árbol?

Ventanas para predecir demanda

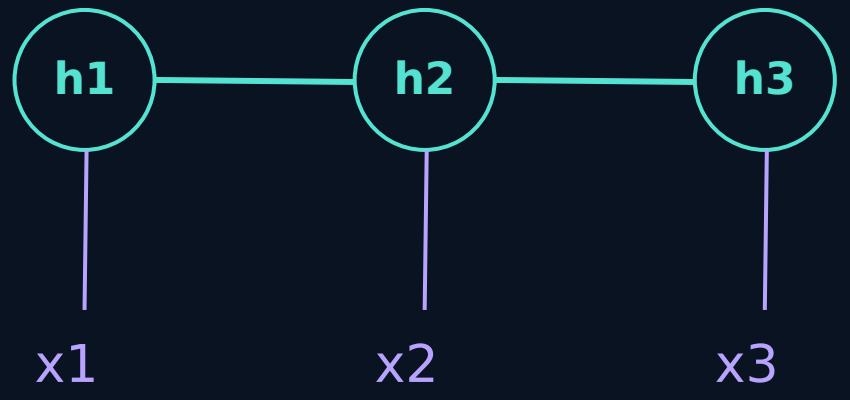
$X_t=[y_{t-3},y_{t-2},y_{t-1},y_t]$
Objetivo=y_{t+1}

Ventana de entrada: cuatro semanas observadas

Objetivo: la semana siguiente

La ventana se construye desde una fecha de origen

Mismos pesos en cada paso



Tiempo / posición

¿La venta de t+1 puede estar en X_t?

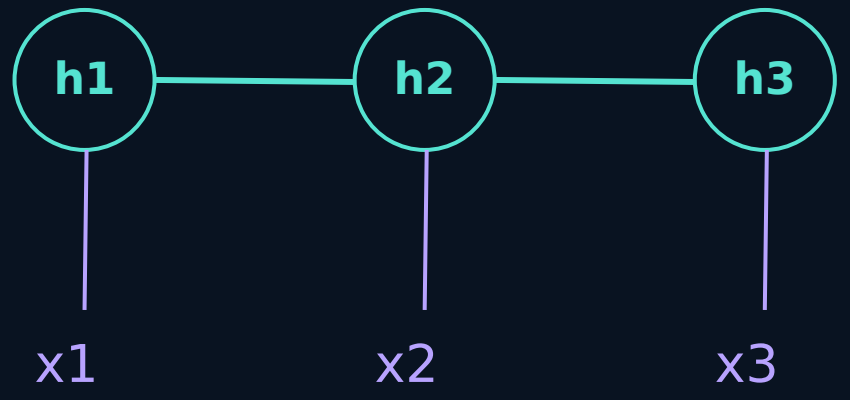
Formas de entrada y salida

Muchos a uno: pronóstico de la siguiente semana

Muchos a muchos: etiquetado por paso

Máscaras permiten longitudes diferentes en un batch

Mismos pesos en cada paso



Tiempo / posición

¿Qué representa la dimensión temporal de una ventana?

La recurrencia transporta un estado

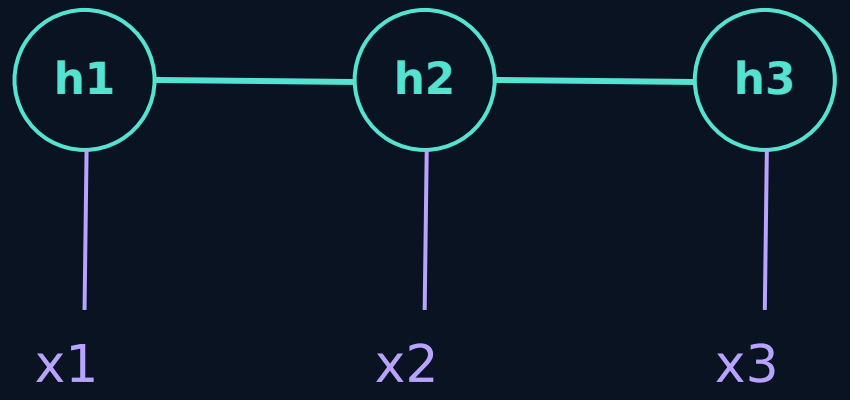
$$h_t = \tanh(W_x x_t + W_h h_{t-1} + b)$$
$$\hat{y}_t = W_y h_t + b_y$$

El estado anterior y la entrada actual producen h_t

La salida puede leerse en cada paso o al final

Los pesos se comparten en el tiempo

Mismos pesos en cada paso



Tiempo / posición

¿Aumentar de 10 a 20 pasos duplica parámetros?

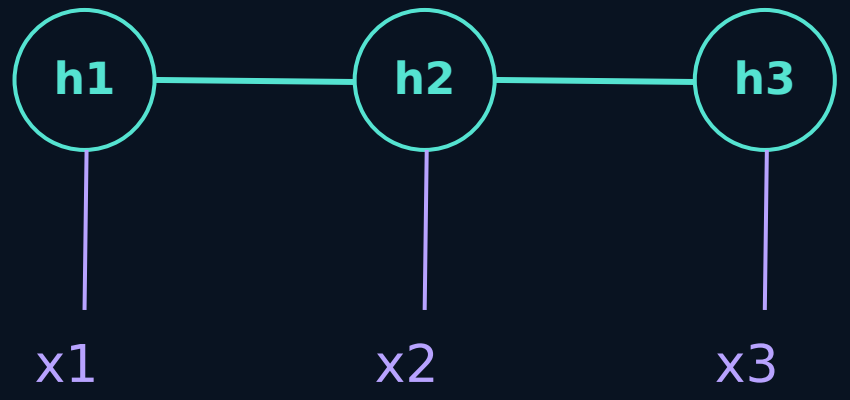
RNN desplegada en el tiempo

Una celda se aplica sucesivamente

El dibujo desplegado muestra dependencias

Cada copia usa exactamente W_x, W_h y b

Mismos pesos en cada paso



Tiempo / posición

¿Qué pasaría si cada paso tuviera pesos distintos?

Parámetros de una RNN

$P_{oculta} = md + m^2 + m$
$d=2, m=3: 6+9+3=18$
$P_{salida}=3+1$, total=22

d atributos, m unidades ocultas y una salida

W_x es $m \times d$ y W_h es $m \times m$

Usamos un único sesgo oculto en esta convención

22 parámetros

Valores didácticos verificables

¿Por qué aparece m^2?

Forward de una RNN escalar

$h_1=\tanh(1)=0{,}761594$
$h_2=\tanh(0{,}5\cdot h_1)=0{,}363399$

$h_0=0$, $W_x=1$, $W_h=0{,}5$ y $b=0$

Entradas: $x_1=1$, $x_2=0$

Los estados cambian aunque la segunda entrada sea cero

$h_2 = 0{,}363399$

Valores didácticos verificables

¿Cuánto vale h_2 si $W_h=0$?

Pérdida sobre una secuencia

$$L = \Sigma_t \, \ell(\hat{y}_t, y_t)$$

Puede evaluarse en todos los pasos observados

También puede usarse solo la salida final

El enmascarado evita puntuar padding

¿Dos pérdidas con igual mínimo pueden generar pasos distintos?

BPTT aplica la regla de la cadena

$\partial L/\partial W_h = \Sigma_t$ contribución del paso t

Primero se despliega la secuencia

Luego se propagan gradientes hacia el pasado

Los usos repetidos de un peso suman contribuciones

$\partial z/\partial w$

$\partial p/\partial z$

$\partial L/\partial p$

¿BPTT necesita un optimizador especial?

Productos temporales de Jacobianos

$$J_t = \mathrm{diag}(1 - h_t^2) W_h$$
$$\partial h_t / \partial h_{t-k} = J_t J_{t-1} \dots J_{t-k+1}$$

Cada paso multiplica por una matriz local

Sus efectos pueden contraerse o amplificarse

Importan activación, pesos y trayectoria



¿Por qué tanh saturada puede dificultar el aprendizaje?

Vanishing y exploding gradients

$0{,}5^{20} \approx 0{,}000000954$
$1{,}5^{20} \approx 3.325{,}26$

Ejemplo escalar con sensibilidad constante

0,5 por paso atenúa la señal

1,5 por paso puede amplificarla



¿Una dependencia larga exige siempre recordar literalmente cada dato?

Clipping y BPTT truncada

$g_{clip} = g \cdot \min(1, \tau / \|g\|)$

Clipping limita la norma de gradientes grandes

Truncar reduce el horizonte del grafo de derivadas

Mantener estado no equivale a mantener todos los gradientes

¿Truncar a 20 pasos permite atribuir directamente una pérdida a 100 pasos atrás?

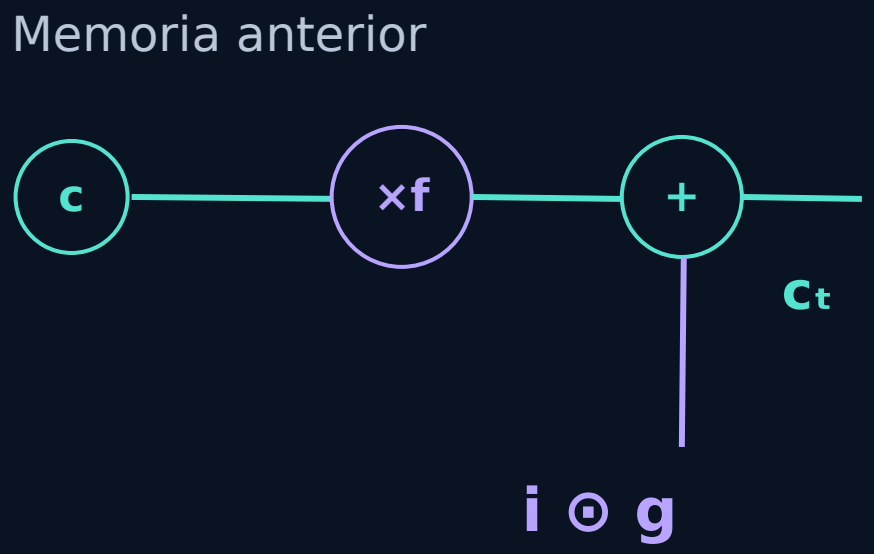
LSTM agrega memoria controlada

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t$$
$$h_t = o_t \odot \tanh(c_t)$$

c_t: estado de celda

h_t: estado oculto expuesto

Gates regulan conservación, escritura y salida



$$h_t = o_t \odot \tanh(c_t)$$

¿Por qué se necesitan c y h?

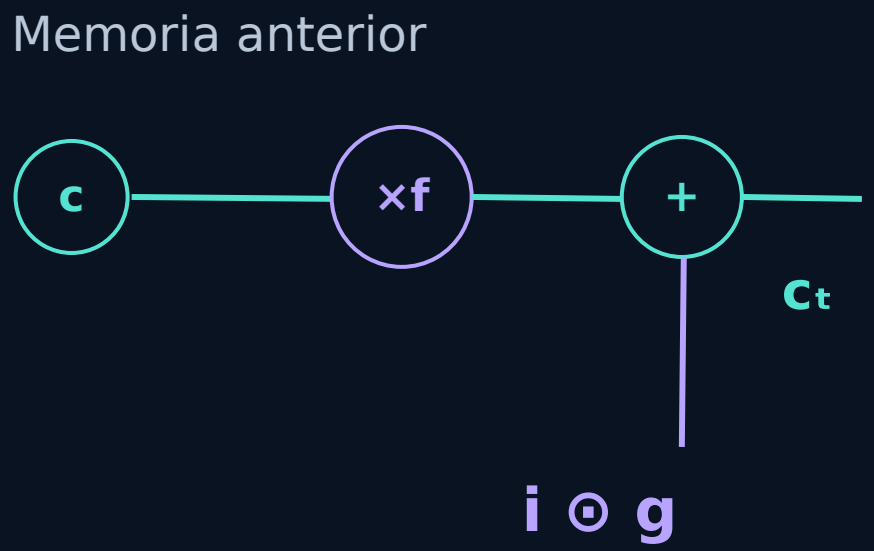
Compuerta de olvido

$$u_t = [h_{t-1}; x_t]$$
$$f_t = \sigma(W_f\, u_t + b_f)$$

Concatena entrada actual y estado oculto previo

La sigmoide produce valores entre 0 y 1

Cada componente escala una memoria previa



$$h_t = o_t \odot \tanh(c_t)$$

¿Qué implica $f_t = 0$ en una componente?

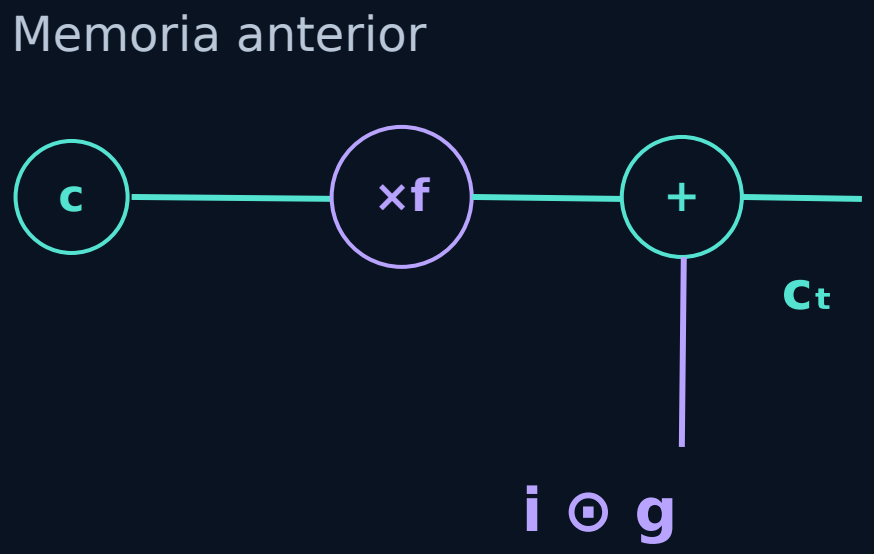
Entrada y contenido candidato

$$i_t = \sigma(W_i u_t + b_i)$$
$$g_t = \tanh(W_g u_t + b_g)$$

i_t decide cuánto escribir por componente

g_t propone contenido con signo

Una misma i puede introducir valores positivos o negativos



$$h_t = o_t \odot \tanh(c_t)$$

¿Abrir i siempre aumenta c?

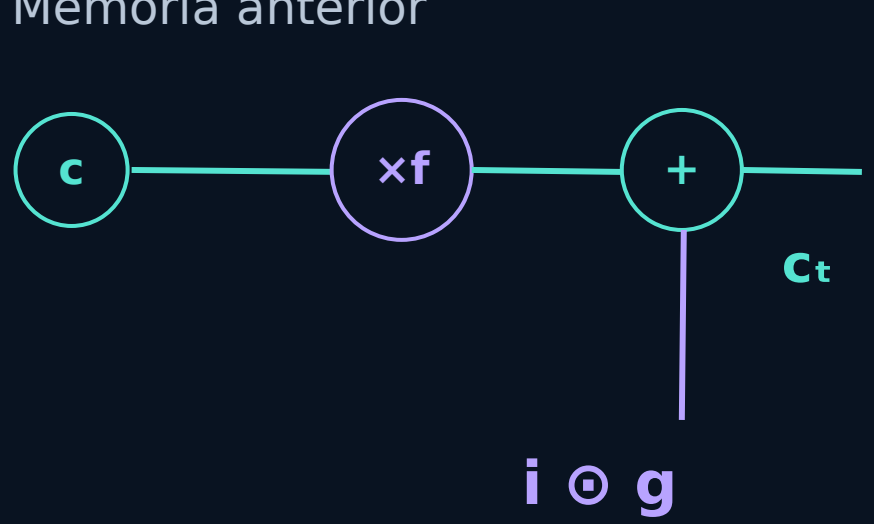
Actualización aditiva de la celda

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t$$

Una rama conserva el pasado

Otra agrega nueva información

c puede superar el intervalo (−1,1)



$$h_t = o_t \odot \tanh(c_t)$$

¿Puede c=2 aunque g esté entre −1 y 1?

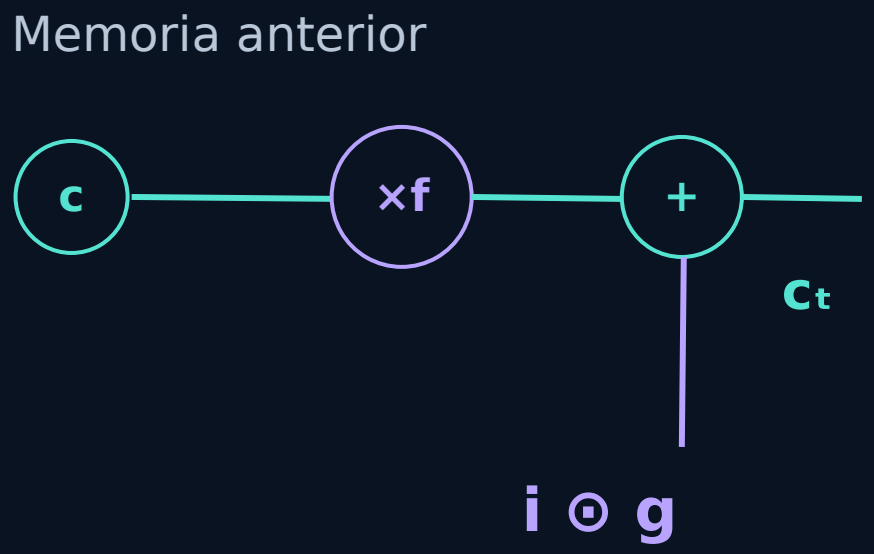
Compuerta de salida y estado oculto

$o_t = \sigma(W_o\, u_t + b_o)$
$h_t = o_t \odot \tanh(c_t)$

o controla la exposición de la memoria

tanh acota lo que se expone

Memoria presente puede permanecer poco visible



$$h_t = o_t \odot \tanh(c_t)$$

¿o=0 obliga a c=0?

LSTM: ecuaciones completas

$$f=\sigma(W_f u+b_f) \quad i=\sigma(W_i u+b_i)$$
$$g=\tanh(W_g u+b_g) \quad o=\sigma(W_o u+b_o)$$
$$c=f\odot c_{anterior}+i\odot g \quad h=o\odot\tanh(c)$$

Una única convención para u=[h anterior;x]

Sigmoide para f, i y o

tanh para g y para la exposición de c

¿Cuáles son los parámetros entrenables?

Ejemplo: conservar y escribir

$c_t = 0{,}9 \cdot 0{,}8 + 0{,}2 \cdot (-0{,}5) = 0{,}62$

$c_{t-1} = 0{,}8$; $f = 0{,}9$; $i = 0{,}2$; $g = -0{,}5$

Memoria conservada: 0,72

Escritura: −0,10

$c_t = 0{,}62$

Valores didácticos verificables

¿Cuánto vale c_t si $i=0$?

Ejemplo: exponer la memoria

$h_t = 0{,}75 \cdot \tanh(0{,}62) \approx 0{,}413346$

Usamos $c_t = 0{,}62$ y $o = 0{,}75$

$\tanh(0{,}62) \approx 0{,}551128$

h queda menor que c y acotado por o

$h_t = 0{,}413346$

Valores didácticos verificables

¿Qué memoria ve la capa de salida si o baja?

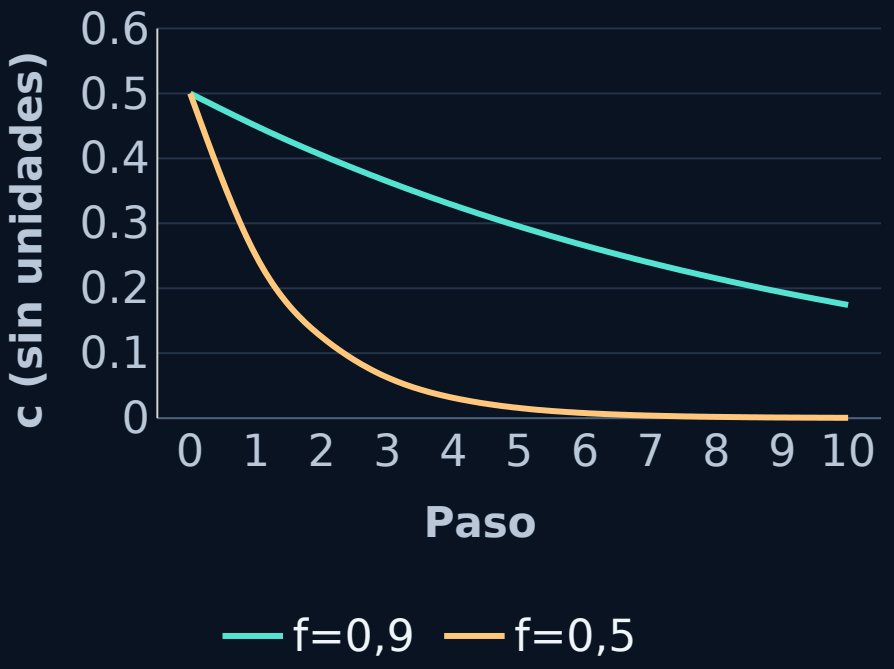
Persistencia con gates constantes

$c_t = 0{,}5 \cdot f^{t-1}$
f=0,9: vida media ≈6,58 pasos

Impulso inicial con i=0,5 y g_1=1

Después no entra contenido: g_t=0

f controla la velocidad de decaimiento



¿Qué sucede si f=1 y no llega más contenido?

Qué dice el gradiente directo

$\partial c_t/\partial c_{t-1}$ (gates fijos)$=f_t$

Manteniendo gates fijos, la derivada directa es f_t

Varios pasos multiplican esas compuertas

La derivada total incluye rutas adicionales por los gates



¿LSTM elimina todo vanishing gradient?

Laboratorio: retener, alternar, sobrescribir

Impulso: observar memoria sin nueva escritura

Alternancia: contenido con cambios de signo

Sobrescritura: nueva señal tras varios pasos

Antes de simular

1. Predecir
2. Observar
3. Explicar

¿Qué diferencia observás al cerrar o en vez de cerrar f?

Conteo de parámetros LSTM

P_celda = 4m(d+m+1)
d=2,m=3: P=4·3·6=72

Cuatro transformaciones sobre d+m entradas

m salidas por transformación

Más parámetros permiten control, pero aumentan costo

72 parámetros

Valores didácticos verificables

¿La longitud de la secuencia aparece en P?

GRU: una alternativa con menos compuertas

$$z=\sigma(W_{zx}+U_{zh_{prev}}+b_z)$$
$$r=\sigma(W_{rx}+U_{rh_{prev}}+b_r)$$
$$\tilde{h}=\tanh(Wx+U(r\odot h_{prev})+b)$$
$$h=(1-z)\odot h_{prev}+z\odot\tilde{h}$$

Combina memoria y estado oculto

Usa gates de actualización y reinicio

La convención de z debe quedar explícita

¿Qué conserva el pasado en esta convención?

RNN, LSTM/GRU y Transformer

RNN: estado recurrente y transición simple

LSTM/GRU: gates y recurrencia secuencial

Transformer: atención con información de posición

RNN
Estado recurrente

LSTM / GRU
Gates y recurrencia

Transformer
Atención y posición

¿La atención recibe el orden temporal sin posición ni máscara?

Costo y paralelización dependen del uso

T: longitud de secuencia
m: dimensión del estado

RNN: $O(Tm^2)$ para recurrencia $d \approx m$

Atención densa: $O(T^2m)$ más proyecciones

Inferencia autoregresiva conserva pasos secuenciales

Comparación con evidencia

Mismo protocolo
Costo explícito
Validación separada

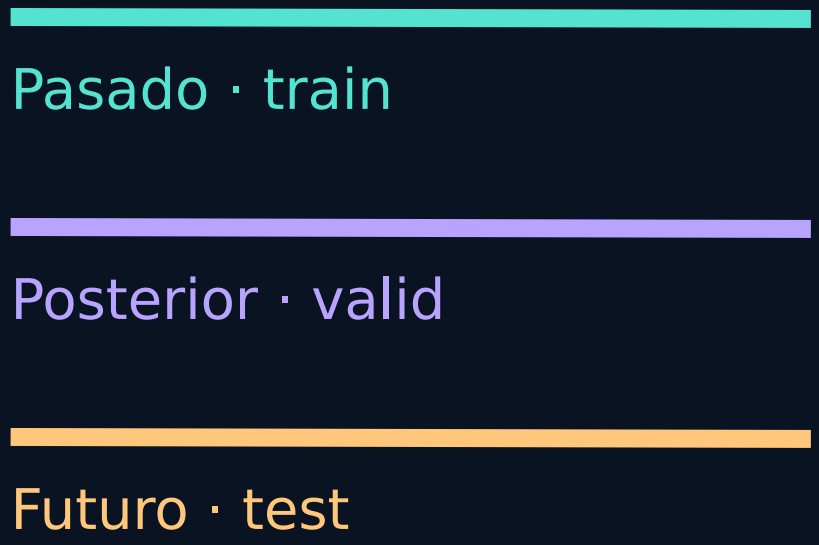
¿Una menor complejidad asintótica garantiza menos latencia para T pequeño?

Partición cronológica para demanda

Entrenar con el pasado disponible

Elegir configuración en un período posterior

Reservar el último bloque como test final



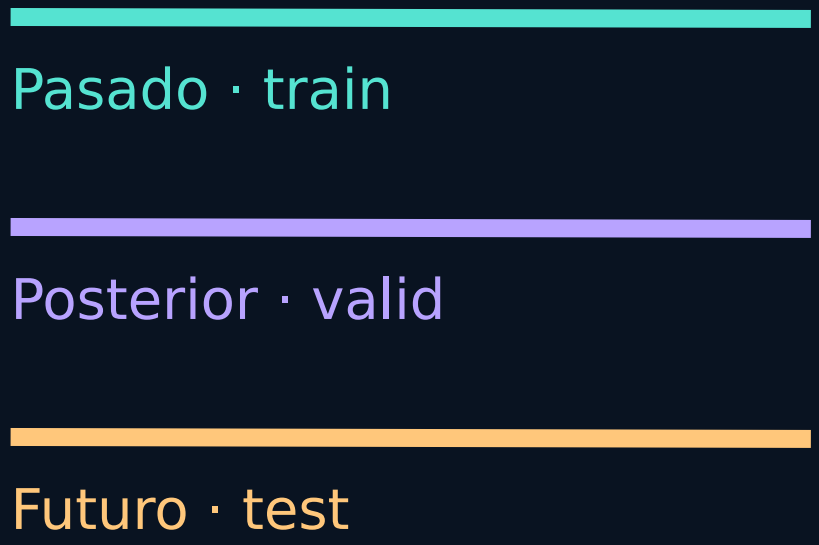
¿Una ventana test puede contener valores de train?

Walk-forward

Cada origen simula una decisión real

Entrenamiento expansivo o ventana móvil

Comparación de modelos sobre los mismos orígenes



¿Por qué un split aleatorio puede sobreestimar calidad temporal?

Baseline ingenuo y estacional

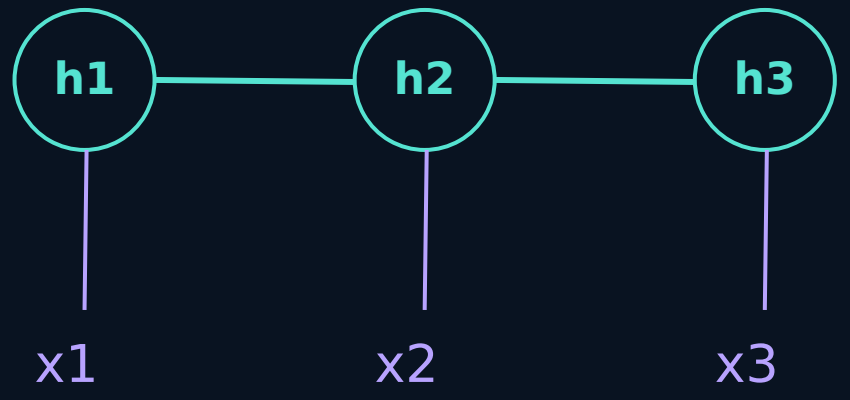
Naive: $\hat{y}_{t+1}=y_t$
Estacional, período s: $\hat{y}_{t+1}=y_{t+1-s}$

Ingenuo: repetir el último dato

Estacional: repetir el mismo período del ciclo previo

Calendario y rezagos también alimentan modelos simples

Mismos pesos en cada paso



Tiempo / posición

¿Qué baseline exigirías para demanda diaria con patrón semanal?

MAE, RMSE y límites de MAPE

$MAE = mean(|e|)$ $RMSE = \sqrt{mean(e^2)}$
$MAPE = 100 \cdot mean(|e/y|)$

MAE conserva unidades e interpreta error absoluto

RMSE penaliza más errores grandes

MAPE falla con ceros y distorsiona valores pequeños

¿Cómo reportarías MAPE si hay $y=0$?

Práctica reproducible en Python

Crear ventanas y separar por fecha

Ajustar baseline estacional, modelo con rezagos y LSTM

Medir MAE/RMSE sobre idénticos orígenes

Defensa con evidencia

1. Protocolo
2. Resultado
3. Límites

¿Qué entregar además del score?

Defensa final y respuestas

Si f=1 e i=0, c se conserva

Clipping limita explosión, sin recuperar gradientes nulos

Una LSTM debe superar un baseline con evidencia temporal

Defensa con evidencia

1. Protocolo
2. Resultado
3. Límites

¿Adoptarías LSTM si la mejora media es pequeña y varía de signo por período?