

MÓDULO 09

Guía integral de simulaciones

Árboles de decisión · Bagging · Random Forest · Interpretabilidad · Boosting · Decisión

16 simulaciones explicadas paso a paso. Cada laboratorio incluye objetivo, fundamento, controles, secuencia de uso, ejemplo, interpretación, errores frecuentes, glosario específico y conexión con la simulación siguiente.

Material hecho por el profesor Sergio Gevaschnaider

Guía de estudio y apoyo docente · 2026

Cómo usar esta guía

Este documento acompaña las simulaciones interactivas del Módulo 09. No reemplaza la experimentación: la organiza. La secuencia recomendada es formular una hipótesis antes de mover un control, ejecutar la simulación, observar qué métricas cambian y recién después leer la interpretación. Ese orden obliga a razonar y evita convertir el laboratorio en una colección de botones.

Los ejemplos de los simuladores son sintéticos y están diseñados con finalidad pedagógica. Sus valores numéricos sirven para entender mecanismos y relaciones; no deben trasladarse como hiperparámetros universales a un problema real. En un proyecto aplicado, cada elección debe validarse con la población, horizonte, función de costo y protocolo de evaluación correspondientes.

Mapa del recorrido

Bloque	Simulaciones
Bloque I · Fundamentos de CART	01 Split óptimo e impureza Gini · 02 Gini vs. Entropía · 03 Árbol ↔ particiones 2D
Bloque II · Complejidad, regularización e inestabilidad	04 Profundidad y overfitting · 05 Poda costo-complejidad · 06 Inestabilidad de un árbol
Bloque III · Bagging y Random Forest	07 Bootstrap y OOB · 08 Bagging · 09 Bagging vs. Random Forest · 10 Número de árboles y OOB · 11 max_features y correlación
Bloque IV · Interpretabilidad	12 MDI vs. permutation importance · 13 Variables correlacionadas · 14 PDP e ICE
Bloque V · Boosting y decisión	15 Gradient Boosting · 16 Decision Lab

Secuencia de estudio sugerida

1. Leer el objetivo y anticipar qué debería ocurrir al mover el control.
2. Manipular una sola variable por vez y registrar la dirección del cambio.
3. Separar métricas de entrenamiento, validación y decisión.
4. Explicar el resultado con una frase causal sobre el algoritmo, no sobre el mundo real: “el modelo hace...”, no “X causa...”.
5. Revisar el glosario específico y responder mentalmente las preguntas de cierre.
6. Usar el puente final para enlazar el concepto con la simulación siguiente.

Contenido

- 01. Split óptimo e impureza Gini** — Bloque I · Fundamentos de CART
- 02. Gini vs. Entropía** — Bloque I · Fundamentos de CART
- 03. Árbol ↔ particiones 2D** — Bloque I · Fundamentos de CART
- 04. Profundidad y overfitting** — Bloque II · Complejidad, regularización e inestabilidad
- 05. Poda costo-complejidad (ccp_alpha)** — Bloque II · Complejidad, regularización e inestabilidad
- 06. Inestabilidad de un árbol** — Bloque II · Complejidad, regularización e inestabilidad
- 07. Bootstrap y Out-of-Bag** — Bloque III · Bagging y Random Forest
- 08. Bagging** — Bloque III · Bagging y Random Forest
- 09. Bagging vs. Random Forest** — Bloque III · Bagging y Random Forest
- 10. Número de árboles y error OOB** — Bloque III · Bagging y Random Forest
- 11. max_features y correlación** — Bloque III · Bagging y Random Forest
- 12. MDI vs. permutation importance** — Bloque IV · Interpretabilidad
- 13. Variables correlacionadas** — Bloque IV · Interpretabilidad
- 14. PDP e ICE** — Bloque IV · Interpretabilidad
- 15. Gradient Boosting** — Bloque V · Boosting y decisión
- 16. Decision Lab: modelo, threshold y costos** — Bloque V · Boosting y decisión

Cierre integrador: del split a la decisión · Glosario general del módulo · Checklist de lectura de modelos

SIMULACIÓN 01 · BLOQUE I · FUNDAMENTOS DE CART

Split óptimo e impureza Gini

Archivo asociado: simulador_01_split_gini.html

Objetivo. Comprender de manera auditable cómo CART selecciona una división: compara umbrales candidatos, calcula la impureza del nodo padre y de los hijos, pondera los hijos por su tamaño y elige la regla que maximiza la reducción de impureza.

$$\text{Gini}(t) = 1 - \sum p_k^2 \quad | \quad \Delta\text{Gini} = \text{Gini}(\text{padre}) - \text{Gini}(\text{split})$$

1. Fundamento conceptual

Esta primera simulación introduce la operación elemental de un árbol de clasificación. Un árbol no “adivina” una regla: en cada nodo examina distintas variables y distintos puntos de corte. Para un umbral t , las observaciones con $X \leq t$ pasan al hijo izquierdo y las restantes al hijo derecho. La calidad de esa división se evalúa comparando cuán mezcladas están las clases antes y después del corte.

La impureza Gini vale cero cuando un nodo contiene una sola clase. En clasificación binaria alcanza su máximo en una mezcla cercana a 50/50. Por eso, un buen split no es simplemente aquel que genera un hijo muy puro; debe mejorar el conjunto de los dos hijos. La simulación hace explícita la impureza ponderada, evitando el error frecuente de mirar solamente el nodo “más lindo”.

El procedimiento es greedy: CART selecciona la mejor decisión local disponible en el nodo actual. Esa decisión condiciona todas las particiones posteriores y no garantiza que el árbol completo sea el óptimo global. La virtud pedagógica del laboratorio es separar la matemática del split de la intuición visual.

2. Qué controla la simulación

Control	Qué modifica	Qué observar
Umbral de monto (t)	Mueve la regla $\text{monto} \leq t$ / $\text{monto} > t$.	Cambios en Gini izquierdo, Gini derecho, Gini ponderado y ganancia.
Usar mejor split	Lleva el control al umbral con máxima ganancia.	Diferencia entre una regla plausible y la mejor regla local según Gini.
Ejemplo guiado	Compara primero un umbral no óptimo y luego el óptimo.	Cómo cambia la ganancia cuando se mueve la frontera.

3. Secuencia de uso recomendada

1. Elegir mentalmente un umbral antes de observar el óptimo.
2. Mover t y leer tamaño, positivos, tasa positiva e impureza de cada hijo.
3. Comparar $\text{Gini}(\text{split})$ con $\text{Gini}(\text{padre})$.
4. Observar el ranking de candidatos y verificar que CART elige la mayor ΔGini .
5. Traducir el split ganador a una regla IF-THEN interpretable.

4. Ejemplo trabajado

El simulador usa 28 observaciones ordenadas por monto y una clase binaria asociada a fraude. Con el valor inicial $t = 5,2$, el Gini del nodo padre es aproximadamente 0,497, el Gini ponderado de los hijos es 0,372 y la ganancia es 0,125. Al explorar todos los candidatos, el mejor corte está en $t = 6,10$: la ganancia aumenta a aproximadamente 0,180. El hijo izquierdo contiene 17 casos, de los cuales 5 son

positivos, mientras que el derecho contiene 11 casos, de los cuales 10 son positivos. La enseñanza no es memorizar 6,10, sino entender por qué esa regla separa mejor las clases para esta muestra.

5. Cómo interpretar el resultado

- Si ΔGini es grande, la división produjo hijos más homogéneos que el padre.
- Si un hijo es pequeño, su impureza recibe poco peso; por eso no puede dominar artificialmente la evaluación.
- El umbral óptimo pertenece a esta muestra y a este criterio. Otro conjunto de datos, otra variable o otro criterio pueden producir otra raíz.

6. Errores frecuentes de interpretación

- Confundir Gini de un nodo con Gini del split.
- Elegir el hijo más puro sin ponderar por tamaño.
- Interpretar el split como relación causal.
- Suponer que el mejor split local garantiza el mejor árbol global.

7. Glosario específico

Término	Definición para estudio
Nodo	Subconjunto de observaciones que comparte el mismo camino de reglas dentro del árbol.
Split	División binaria de un nodo según una variable y un umbral.
Impureza Gini	Medida de mezcla de clases; es cero cuando el nodo es puro.
Impureza ponderada	Promedio de la impureza de los hijos ponderado por su cantidad de observaciones.
Ganancia de Gini	Reducción de impureza conseguida por el split respecto del nodo padre.
Threshold / umbral	Valor numérico utilizado para separar observaciones en dos ramas.
Greedy	Estrategia que elige la mejor decisión local sin explorar todas las secuencias futuras.

8. Puente hacia la simulación siguiente

Conexión. Una vez entendido que CART necesita un criterio para decidir qué split es “mejor”, la pregunta natural es si todas las medidas de impureza ordenan los candidatos de la misma manera. Esa es exactamente la cuestión de la Simulación 02.

SIMULACIÓN 02 · BLOQUE I · FUNDAMENTOS DE CART

Gini vs. Entropía

Archivo asociado: simulador_02_gini_entropia.html

Objetivo. Comparar dos criterios de impureza utilizados para evaluar splits y distinguir entre su escala numérica y el ranking que inducen sobre los candidatos.

$$\text{Gini} = 1 - \sum p_k^2 \quad | \quad H = -\sum p_k \log_2(p_k)$$

1. Fundamento conceptual

Gini y entropía miden la heterogeneidad de un nodo con fórmulas diferentes. La entropía proviene de teoría de la información y cuantifica incertidumbre; Gini puede interpretarse como una medida cuadrática de mezcla. Ambos valen cero en nodos puros y aumentan cuando las clases están más equilibradas.

La comparación relevante para construir el árbol no consiste en preguntar cuál criterio produce “números más grandes”. Las escalas no son directamente comparables. Lo que importa es qué candidato maximiza la reducción de impureza dentro de cada criterio. En muchos conjuntos de datos existe una señal dominante y ambos seleccionan la misma regla; en otros, pequeñas diferencias de sensibilidad modifican el ranking y pueden cambiar el split raíz.

El simulador incluye tres escenarios deliberados: separación clara, solapamiento y un caso en el que los criterios divergen. De esta forma, criterion se entiende como un hiperparámetro que debe evaluarse dentro de un protocolo de validación, no como una preferencia dogmática.

2. Qué controla la simulación

Control	Qué modifica	Qué observar
Escenario	Cambia el patrón de clases manteniendo la escala de X.	Cuándo Gini y entropía coinciden y cuándo divergen.
Umbral observado	Evalúa el mismo corte con ambos criterios.	Las dos ganancias y la posición respecto de cada óptimo.
Óptimo Gini / entropía	Lleva el umbral al mejor candidato de cada criterio.	Cómo una diferencia en la función objetivo puede alterar la raíz.

3. Secuencia de uso recomendada

1. Empezar por “Separación clara” y observar si ambos criterios seleccionan el mismo corte.
2. Pasar a “Solapamiento” y comparar la forma de las curvas de ganancia.
3. Abrir “Criterios divergen” y anotar ambos umbrales óptimos.
4. Evitar comparar la altura absoluta de Gini contra la altura absoluta de entropía; comparar rankings dentro de cada criterio.

4. Ejemplo trabajado

En el escenario “Separación clara”, ambos criterios eligen un umbral de aproximadamente 4,85. En “Solapamiento”, ambos vuelven a coincidir, alrededor de 5,75. El escenario pedagógicamente más importante es “Criterios divergen”: Gini selecciona aproximadamente 2,75, mientras que entropía selecciona aproximadamente 6,65. Un cambio aparentemente pequeño en el criterio puede, por lo tanto, reestructurar todo el árbol desde la raíz.

5. Cómo interpretar el resultado

- Cuando ambos criterios coinciden, la señal dominante supera las diferencias de sensibilidad matemática.
- Cuando divergen, no hay una regla universal que diga que uno es automáticamente superior: la comparación debe hacerse fuera de muestra.
- El criterio influye en las reglas aprendidas, pero no reemplaza controles de profundidad, poda o validación.

6. Errores frecuentes de interpretación

- Comparar magnitudes absolutas de Gini y entropía como si estuvieran en la misma escala.
- Afirmar que entropía siempre produce mejores árboles.
- Elegir criterion mirando el test final.

7. Glosario específico

Término	Definición para estudio
Entropía	Medida informacional de incertidumbre de una distribución de clases.
Information Gain	Reducción de entropía producida por un split.
criterion	Hiperparámetro que define cómo se evalúa la calidad de las divisiones.
Ranking de splits	Orden de los candidatos según la ganancia producida.
Señal dominante	Patrón predictivo tan claro que distintos criterios tienden a preferir la misma regla.
Solapamiento	Situación en la que ambas clases ocupan zonas similares y la separación es más ambigua.

8. Puente hacia la simulación siguiente

Conexión. Hasta aquí el split se estudió como cálculo unidimensional. La Simulación 03 muestra la misma lógica en dos dimensiones: cada pregunta del árbol se convierte en una frontera geométrica y cada hoja en una región del espacio.

SIMULACIÓN 03 · BLOQUE I · FUNDAMENTOS DE CART

Árbol ↔ particiones 2D

Archivo asociado: simulador_03_arbol_particiones_2d.html

Objetivo. Relacionar la representación lógica del árbol con la geometría de sus regiones de decisión y comprender cómo la profundidad crea interacciones y fronteras no lineales mediante cortes paralelos a los ejes.

Si $X_j \leq t \rightarrow$ rama izquierda; si $X_j > t \rightarrow$ rama derecha

1. Fundamento conceptual

Un árbol puede leerse de dos maneras equivalentes. En forma lógica, es una secuencia de preguntas IF-THEN desde la raíz hasta una hoja. En forma geométrica, cada pregunta genera una línea vertical u horizontal en el espacio de características. La combinación de esas líneas crea regiones rectangulares dentro de las cuales el modelo mantiene una predicción constante o una probabilidad de clase.

Esta equivalencia explica por qué los árboles capturan no linealidades sin transformar manualmente las variables. También explica las interacciones: una segunda pregunta se formula solamente dentro de la región creada por una pregunta previa, de modo que el efecto operativo de una variable depende del camino recorrido.

La profundidad máxima controla cuántas decisiones pueden encadenarse. A mayor profundidad, el árbol dispone de más regiones y puede ajustar formas más complejas. Esa capacidad es útil para aproximar fronteras curvas, pero también abre la puerta al sobreajuste.

2. Qué controla la simulación

Control	Qué modifica	Qué observar
Profundidad máxima	Limita la cantidad de niveles de decisiones.	Número de hojas, profundidad efectiva, accuracy de entrenamiento y cantidad de regiones.
Restablecer	Vuelve a profundidad 2.	Comparar una representación compacta con árboles más complejos.

3. Secuencia de uso recomendada

1. Observar primero el árbol textual con profundidad baja.
2. Identificar una regla y buscar su línea equivalente en el espacio 2D.
3. Aumentar la profundidad y contar cómo crecen las hojas y las regiones.
4. Reconocer que cada hoja corresponde a un rectángulo y que su probabilidad surge de los casos que llegan a ella.

4. Ejemplo trabajado

El laboratorio genera 180 observaciones sintéticas con dos variables y un patrón aproximadamente circular con 8% de ruido. Como CART solo realiza cortes alineados con los ejes, una frontera curva se aproxima mediante varios rectángulos. Con profundidad 1 o 2 el patrón queda resumido de manera gruesa; al aumentar la profundidad aparecen regiones más pequeñas que siguen mejor la forma de los datos.

5. Cómo interpretar el resultado

- Más hojas equivalen a más segmentos locales y mayor flexibilidad.
- Una frontera escalonada no es un error visual: es la geometría natural de reglas axis-aligned.
- Una probabilidad de hoja es una estimación local basada en la proporción positiva del segmento.

6. Errores frecuentes de interpretación

- Creer que un árbol crea fronteras oblicuas en cada split estándar.
- Confundir profundidad máxima con número de hojas.
- Interpretar más accuracy de entrenamiento como prueba de mejor generalización.

7. Glosario específico

Término	Definición para estudio
Partición recursiva	Proceso de dividir sucesivamente el espacio en regiones más pequeñas.
Frontera de decisión	Límite que separa regiones donde el modelo asigna clases diferentes.
Hoja	Nodo terminal que emite la predicción.
Profundidad	Cantidad máxima de decisiones desde la raíz hasta una hoja.
Interacción	Dependencia por la cual el efecto de una variable cambia según condiciones previas de otras.
Región rectangular	Área del espacio creada por una secuencia de cortes paralelos a los ejes.

8. Puente hacia la simulación siguiente

Conexión. La geometría muestra que aumentar profundidad incrementa capacidad. La Simulación 04 formula la pregunta siguiente: ¿cuándo esa capacidad deja de capturar señal útil y empieza a aprender ruido?

SIMULACIÓN 04 · BLOQUE II · COMPLEJIDAD, REGULARIZACIÓN E INESTABILIDAD

Profundidad y overfitting

Archivo asociado: simulador_04_profundidad_overfitting.html

Objetivo. Visualizar el trade-off sesgo-varianza observando simultáneamente accuracy de entrenamiento, accuracy de validación, brecha entre ambas y complejidad del árbol.

Complejidad ↑ → sesgo tiende a ↓, varianza puede ↑

1. Fundamento conceptual

Un árbol muy pequeño puede ser incapaz de representar la estructura real: su sesgo es alto. A medida que se incrementa `max_depth`, el entrenamiento suele mejorar porque el modelo dispone de más reglas y más hojas. Sin embargo, el desempeño fuera de muestra no tiene por qué seguir la misma trayectoria.

El sobreajuste aparece cuando el modelo utiliza capacidad adicional para describir peculiaridades de la muestra de entrenamiento que no se repiten en datos nuevos. En la simulación, la señal se detecta al separar las curvas de train y validación: train puede seguir subiendo mientras validación se estanca o cae.

La profundidad no debe elegirse por el mayor score de entrenamiento. El objetivo es minimizar el error esperado fuera de muestra. Por eso la simulación reserva un conjunto de validación independiente y marca el punto donde la validación alcanza su máximo dentro de la grilla explorada.

2. Qué controla la simulación

Control	Qué modifica	Qué observar
<code>max_depth</code> (1 a 12)	Cambia la complejidad estructural del árbol.	Accuracy train, validación, brecha y número de hojas.
Mejor validación	Salta al punto de mayor accuracy de validación en la simulación.	Que el óptimo fuera de muestra puede ocurrir antes que el máximo ajuste in-sample.

3. Secuencia de uso recomendada

1. Recorrer profundidades desde 1 hacia arriba.
2. Registrar cómo evoluciona train y validación.
3. Identificar el máximo de validación y observar qué ocurre después.
4. Relacionar la brecha train-validación con la frontera gráfica cada vez más fragmentada.

4. Ejemplo trabajado

La simulación entrena con 220 observaciones y valida sobre 600 observaciones nuevas; ambos conjuntos contienen 18% de ruido. Para cada profundidad de 1 a 12 se construye un árbol nuevo con el mismo protocolo. El caso ilustra que una profundidad adicional puede aumentar el accuracy de entrenamiento y, al mismo tiempo, ampliar la brecha respecto de validación. Ese patrón es la señal que interesa, no un número de profundidad universal.

5. Cómo interpretar el resultado

- Una brecha creciente es compatible con alta varianza.
- Si ambas curvas son bajas y cercanas, puede existir underfitting.
- El punto de mejor validación depende de datos, ruido, tamaño muestral, métrica y otros hiperparámetros.

6. Errores frecuentes de interpretación

- Seleccionar max_depth con train accuracy.
- Usar el test final para buscar la profundidad.
- Creer que el sobreajuste solo ocurre cuando train llega a 100%.

7. Glosario específico

Término	Definición para estudio
Overfitting	Ajuste excesivo a particularidades del entrenamiento que deteriora generalización.
Underfitting	Modelo demasiado simple para representar la estructura predictiva.
Sesgo	Error sistemático asociado a una representación demasiado rígida.
Varianza	Sensibilidad de la solución a cambios en la muestra de entrenamiento.
Generalización	Capacidad de mantener desempeño sobre observaciones no usadas para ajustar el modelo.
Brecha train-validación	Diferencia de desempeño que ayuda a diagnosticar exceso de capacidad.

8. Puente hacia la simulación siguiente

Conexión. Una forma de limitar complejidad es impedir que el árbol crezca. Otra es dejarlo crecer y luego eliminar ramas que no justifican su costo. La Simulación 05 presenta esta segunda estrategia: poda costo-complejidad.

SIMULACIÓN 05 · BLOQUE II · COMPLEJIDAD, REGULARIZACIÓN E INESTABILIDAD

Poda costo-complejidad (ccp_alpha)

Archivo asociado: simulador_05_poda_ccp_alpha.html

Objetivo. Entender la poda posterior como una regularización explícita que intercambia ajuste por simplicidad y aprender a seleccionar ccp_alpha con validación.

$$R_{\alpha}(T) = R(T) + \alpha |T|$$

1. Fundamento conceptual

La poda costo-complejidad parte de un árbol relativamente grande y plantea que cada hoja debe “pagar” un costo adicional. $R(T)$ representa el error del árbol y $|T|$ su número de hojas. El parámetro α regula cuánto se penaliza la complejidad: cuando α es pequeño, conservar ramas cuesta poco; cuando aumenta, una rama debe aportar una mejora suficientemente grande para justificar su existencia.

La simulación implementa post-pruning. Esto permite ver que simplificar no significa necesariamente empeorar: una poda moderada puede reducir varianza y mejorar validación aun cuando el score de entrenamiento caiga. Si α se vuelve demasiado alto, el árbol termina demasiado simple y aparece subajuste.

La elección de α es un problema de selección de modelo. Debe realizarse sobre validación o validación cruzada. El test final debe quedar reservado para una evaluación posterior, una vez fijada la política de complejidad.

2. Qué controla la simulación

Control	Qué modifica	Qué observar
ccp_alpha (0 a 0,08)	Penaliza cada hoja terminal.	Cantidad de hojas, profundidad, train y validación.
α con mejor validación	Ubica el mejor punto de la grilla del laboratorio.	Que el árbol con mejor generalización puede ser más pequeño que el árbol completo.

3. Secuencia de uso recomendada

1. Observar el árbol con α bajo.
2. Aumentar α gradualmente y registrar cuándo desaparecen ramas.
3. Comparar la caída de train con la evolución de validación.
4. Identificar el rango en el que la simplificación mejora o conserva desempeño fuera de muestra.

4. Ejemplo trabajado

El laboratorio genera 240 casos de entrenamiento y 650 de validación con 16% de ruido. Primero construye un árbol de profundidad máxima 10 y luego evalúa valores de α desde 0 hasta 0,08 en pasos de 0,002. Con α inicial 0,012 puede verse un árbol ya simplificado; el botón “ α con mejor validación” muestra el candidato que, para esta muestra particular, ofrece el mejor compromiso.

5. Cómo interpretar el resultado

- α no es una probabilidad ni un umbral de clasificación; es un parámetro de regularización estructural.
- Menos hojas pueden producir mejor validación si se eliminaron ramas que capturaban ruido.
- El “mejor α ” del simulador no debe trasladarse mecánicamente a otro problema.

6. Errores frecuentes de interpretación

- Confundir poda con reducción del threshold de clasificación.
- Elegir α por estética del árbol.
- Suponer que el árbol más pequeño siempre generaliza mejor.

7. Glosario específico

Término	Definición para estudio
Post-pruning	Poda aplicada después de permitir que el árbol crezca.
Costo-complejidad	Criterio que combina error de ajuste con una penalización por tamaño.
ccp_alpha	Parámetro que determina la fuerza de la penalización por hojas.
Regularización	Mecanismo que restringe capacidad para favorecer generalización.
Subárbol	Árbol obtenido al eliminar determinadas ramas del árbol original.
Familia de candidatos	Conjunto de modelos de distinta complejidad entre los que selecciona validación.

8. Puente hacia la simulación siguiente

Conexión. Incluso un árbol razonablemente regularizado puede ser inestable: pequeñas modificaciones de la muestra pueden cambiar la raíz y muchas ramas. La Simulación 06 muestra esa alta varianza de manera directa.

SIMULACIÓN 06 · BLOQUE II · COMPLEJIDAD, REGULARIZACIÓN E INESTABILIDAD

Inestabilidad de un árbol

Archivo asociado: simulador_06_inestabilidad_arbol.html

Objetivo. Demostrar empíricamente la alta varianza de los árboles individuales y conectar esa debilidad con la motivación estadística de Bagging.

Pequeña perturbación de datos → posible gran cambio estructural

1. Fundamento conceptual

Los árboles son modelos discontinuos respecto de los datos: una pequeña modificación de observaciones cercanas a una frontera puede cambiar qué split resulta ganador. Si cambia la raíz, todos los nodos descendientes se entrenan sobre subconjuntos diferentes y la alteración puede propagarse por gran parte del árbol.

La simulación construye dos árboles con la misma configuración. El árbol A utiliza las etiquetas originales y el árbol B recibe unas pocas inversiones de clase en observaciones cercanas a la frontera. Luego se comparan las raíces, el número de hojas y las predicciones sobre una grilla densa. El mapa amarillo muestra las zonas donde ambos árboles discrepan.

La idea central es que un árbol puede ser interpretable y, al mismo tiempo, inestable. Esa inestabilidad es una manifestación de alta varianza. Bagging surge precisamente como respuesta: si diferentes muestras producen árboles distintos, promediar muchos de ellos puede cancelar parte de la variación idiosincrática.

2. Qué controla la simulación

Control	Qué modifica	Qué observar
Observaciones perturbadas (0 a 25)	Invierte etiquetas de casos cercanos a la frontera.	Acuerdo de predicción, split raíz y hojas de los dos árboles.
Nueva perturbación	Cambia cuáles casos son alterados.	Que el fenómeno no depende de una única realización.

3. Secuencia de uso recomendada

1. Comenzar con pocas perturbaciones.
2. Comparar el split raíz A y B.
3. Observar el porcentaje de acuerdo sobre la grilla.
4. Aumentar la perturbación y localizar las regiones amarillas de desacuerdo.
5. Relacionar la sensibilidad observada con el concepto de varianza.

4. Ejemplo trabajado

La base contiene 170 observaciones con 12% de ruido. Ambos árboles usan profundidad máxima 5 y tamaño mínimo de hoja 4. El control inicial modifica solo 3 etiquetas seleccionadas cerca de la frontera. Aunque 3 casos representan una porción pequeña del conjunto, pueden cambiar reglas y regiones completas. La simulación no pretende demostrar que cualquier perturbación cambia la raíz, sino mostrar que esa posibilidad existe y es estructuralmente importante.

5. Cómo interpretar el resultado

- La estabilidad de predicción y la estabilidad de reglas son dimensiones relacionadas pero no idénticas.
- Dos árboles pueden tener accuracy parecido y reglas muy diferentes.
- La inestabilidad no se “cura” simplemente aumentando profundidad; normalmente la agrava.

6. Errores frecuentes de interpretación

- Confundir sensibilidad de muestra con error de programación.
- Pensar que interpretabilidad implica robustez estructural.
- Comparar solo accuracy y omitir acuerdo de predicciones o reglas.

7. Glosario específico

Término	Definición para estudio
Inestabilidad	Cambios relevantes en el modelo ante perturbaciones pequeñas de los datos.
Alta varianza	Dependencia fuerte de la solución respecto de la muestra concreta.
Acuerdo de predicción	Proporción del espacio o de casos donde dos modelos producen la misma clase.
Perturbación	Modificación controlada de datos para evaluar sensibilidad.
Frontera	Zona donde pequeñas variaciones pueden cambiar la clase predicha.
Robustez	Capacidad de mantener comportamiento razonablemente estable ante cambios limitados.

8. Puente hacia la simulación siguiente

Conexión. Si distintos conjuntos de datos producen árboles distintos, necesitamos una forma sistemática de generar esas variaciones. La Simulación 07 introduce el bootstrap y, junto con él, el conjunto Out-of-Bag que luego permitirá validar internamente cada árbol.

SIMULACIÓN 07 · BLOQUE III · BAGGING Y RANDOM FOREST

Bootstrap y Out-of-Bag

Archivo asociado: simulador_07_bootstrap_oob.html

Objetivo. Comprender el remuestreo con reemplazo, la aparición de duplicados y la razón por la cual una fracción cercana al 36,8% queda fuera de cada muestra bootstrap.

$$P(\text{OOB}) = (1 - 1/n)^n \rightarrow e^{-1} \approx 36,8\%$$

1. Fundamento conceptual

Bootstrap construye una nueva muestra de tamaño n realizando n extracciones con reemplazo desde las n observaciones originales. “Con reemplazo” significa que un caso puede seleccionarse varias veces mientras que otro puede no aparecer nunca. Los casos seleccionados forman el conjunto in-bag de ese árbol.

Para una observación cualquiera, la probabilidad de no ser seleccionada en una extracción es $1 - 1/n$. La probabilidad de quedar fuera en las n extracciones es $(1 - 1/n)^n$, que converge a e^{-1} , aproximadamente 36,8%. Esos casos no vistos por un árbol se denominan Out-of-Bag y pueden usarse para evaluar ese árbol sin reservar una nueva partición para cada bootstrap.

El porcentaje OOB observado fluctúa en cada realización; 36,8% es una expectativa asintótica, no una obligación exacta. La simulación hace visible la distribución de frecuencias: barras azules para casos seleccionados y barras amarillas para casos OOB.

2. Qué controla la simulación

Control	Qué modifica	Qué observar
Tamaño n (20 a 200)	Cambia la cantidad de observaciones y de extracciones.	OOB observado, OOB teórico, duplicados y máximo de repeticiones.
Nuevo bootstrap	Genera otra realización aleatoria.	Fluctuación alrededor del valor teórico.

3. Secuencia de uso recomendada

1. Fijar n y generar varias muestras.
2. Contar cuántas observaciones aparecen cero, una o varias veces.
3. Comparar OOB observado con $(1 - 1/n)^n$.
4. Aumentar n y comprobar que el valor teórico se acerca a 36,8%.

4. Ejemplo trabajado

Con $n = 80$, el valor teórico es aproximadamente 36,6%. En la realización inicial del simulador quedan 24 casos OOB, es decir 30%, aparecen 17 observaciones duplicadas y una observación llega a repetirse 5 veces. Otra realización dará números diferentes. Esa variabilidad es precisamente lo que muestra la simulación: el 36,8% describe un comportamiento promedio, no una cuota fija.

5. Cómo interpretar el resultado

- OOB no significa “datos eliminados”; son datos no usados por un árbol concreto.
- Una misma observación puede ser in-bag para algunos árboles y OOB para otros.
- La evaluación OOB del bosque se construye agregando únicamente predicciones de árboles que no vieron cada observación.

6. Errores frecuentes de interpretación

- Pensar que bootstrap es muestreo sin reemplazo.
- Creer que el conjunto bootstrap contiene n casos únicos.
- Interpretar 36,8% como porcentaje exacto en cada árbol.

7. Glosario específico

Término	Definición para estudio
Bootstrap	Remuestreo con reemplazo utilizado para generar muestras de entrenamiento alternativas.
In-bag	Observaciones seleccionadas al menos una vez para entrenar un árbol.
Out-of-Bag (OOB)	Observaciones no seleccionadas en el bootstrap de un árbol.
Con reemplazo	Esquema donde una observación puede ser elegida más de una vez.
Duplicado	Observación que aparece varias veces en la misma muestra bootstrap.
Validación interna	Evaluación obtenida usando información no empleada por el modelo específico que genera la predicción.

8. Puente hacia la simulación siguiente

Conexión. Bootstrap genera árboles diferentes. La Simulación 08 responde qué ocurre al agregarlos: aunque cada árbol sea inestable, el promedio o voto puede producir una predicción mucho más estable.

SIMULACIÓN 08 · BLOQUE III · BAGGING Y RANDOM FOREST

Bagging

Archivo asociado: simulador_08_bagging.html

Objetivo. Observar cómo la agregación de árboles entrenados sobre bootstraps distintos reduce varianza y estabiliza la frontera de decisión.

$$\bar{f}(x) = (1/B) \sum f_b(x)$$

1. Fundamento conceptual

Bagging significa Bootstrap Aggregating. El procedimiento genera B muestras bootstrap, ajusta un árbol en cada una y combina sus predicciones. En clasificación puede promediar probabilidades o contabilizar votos; en regresión promedia respuestas. Su objetivo principal es reducir varianza sin exigir que el árbol individual deje de ser flexible.

El principio estadístico es que el promedio de estimadores ruidosos puede ser más estable que cualquiera de ellos. La mejora depende de que los errores no estén perfectamente correlacionados. Si todos los árboles se equivocaran exactamente en los mismos casos, promediarlos aportaría poco.

La simulación mantiene disponibles todas las variables en cada split; por eso es Bagging y todavía no Random Forest. Permite variar el número de árboles B y su profundidad, comparar el primer árbol con el ensemble y visualizar la confianza del voto sobre el espacio.

2. Qué controla la simulación

Control	Qué modifica	Qué observar
Número de árboles B	Cantidad de modelos agregados.	Accuracy del ensemble y estabilización del voto.
Profundidad	Complejidad de cada árbol base.	Relación entre árboles fuertes, inestabilidad individual y beneficio de agregación.

3. Secuencia de uso recomendada

1. Empezar con B pequeño y observar dependencia de una realización particular.
2. Aumentar B manteniendo profundidad fija.
3. Comparar accuracy del primer árbol contra accuracy del Bagging.
4. Observar zonas de ambigüedad, donde el promedio está cerca de 0,5.

4. Ejemplo trabajado

El laboratorio usa 260 casos de entrenamiento y 700 de validación, con 20% de ruido. El valor inicial emplea B = 21 árboles de profundidad 6. Cada árbol recibe un bootstrap distinto, pero en cada nodo puede considerar las dos variables. Al aumentar B, la frontera deja de depender tanto de un árbol particular y el voto se vuelve más estable; la mejora marginal, sin embargo, suele disminuir a medida que el ensemble ya contiene muchos árboles.

5. Cómo interpretar el resultado

- Bagging reduce principalmente varianza; no corrige automáticamente un sesgo sistemático del algoritmo base.
- Más árboles no suelen provocar overfitting de la misma forma que aumentar profundidad de un árbol individual; el principal costo adicional es computacional.
- La diversidad útil proviene aquí del remuestreo de filas.

6. Errores frecuentes de interpretación

- Llamar Random Forest a cualquier conjunto de árboles.
- Esperar que cada árbol individual sea estable.
- Suponer que B infinito corrige leakage o una mala definición del objetivo.

7. Glosario específico

Término	Definición para estudio
Bagging	Ensemble que combina modelos entrenados sobre muestras bootstrap.
Ensemble	Conjunto de modelos cuyas salidas se agregan.
Voto	Regla de combinación de predicciones de clasificación.
Promedio de probabilidades	Agregación continua que permite obtener un score del ensemble.
Diversidad	Diferencia de errores o reglas entre modelos base.
Rendimientos decrecientes	Situación en la que cada árbol adicional aporta una mejora cada vez menor.

8. Puente hacia la simulación siguiente

Conexión. Bagging cambia las filas que ve cada árbol, pero variables predictoras muy dominantes pueden hacer que muchos árboles se parezcan. Random Forest agrega una segunda fuente de aleatoriedad: restringe qué variables pueden competir en cada split. Eso se estudia en la Simulación 09.

SIMULACIÓN 09 · BLOQUE III · BAGGING Y RANDOM FOREST

Bagging vs. Random Forest

Archivo asociado: simulador_09_random_forest.html

Objetivo. Distinguir Bagging de Random Forest y analizar cómo `max_features` modifica la correlación entre árboles y el desempeño del ensemble.

Random Forest = bootstrap de filas + subespacio aleatorio de variables

1. Fundamento conceptual

En Bagging, cada árbol recibe una muestra bootstrap diferente pero, al buscar un split, puede comparar todas las variables. Si existe un predictor muy dominante, muchos árboles tenderán a elegirlo cerca de la raíz y sus errores seguirán estando correlacionados.

Random Forest introduce random subspace: en cada nodo se selecciona aleatoriamente un subconjunto de variables y solamente esas variables pueden competir. El objetivo no es fabricar árboles individualmente óptimos, sino construir árboles suficientemente buenos cuyos errores sean menos redundantes.

El parámetro `max_features`, también conocido conceptualmente como `mtry`, controla ese compromiso. Un valor alto fortalece a cada árbol pero puede aumentar correlación; un valor muy bajo aumenta diversidad, aunque puede privar a algunos nodos de señal útil.

2. Qué controla la simulación

Control	Qué modifica	Qué observar
<code>max_features</code> (1 a 6)	Número de predictores candidatos por split.	Accuracy RF, correlación entre árboles y diferencia con Bagging.
Número de árboles B	Tamaño del bosque.	Estabilidad de las métricas y estimación OOB.

3. Secuencia de uso recomendada

1. Fijar B y comenzar con `max_features = 6`: ese caso equivale a Bagging respecto de selección de variables.
2. Reducir `max_features` y observar correlación media.
3. Comparar accuracy del RF con el Bagging de referencia.
4. Leer simultáneamente OOB accuracy y validación externa.

4. Ejemplo trabajado

El laboratorio usa un conjunto sintético de seguros con 430 observaciones y seis predictores: Monto, Historial, Edad, Canal, Monto correlacionado y Ruido. Con `max_features = 2` y `B = 60`, cada nodo puede evaluar solo dos de las seis variables. El Bagging de comparación utiliza las seis. El interés no está en que Random Forest “siempre gane”, sino en visualizar el equilibrio entre fuerza individual y decorrelación.

5. Cómo interpretar el resultado

- Cuando `max_features = p`, desaparece el random subspace y el método se aproxima a Bagging.
- Una correlación menor puede ser beneficiosa aun si el árbol medio se vuelve ligeramente más débil.
- La mejor configuración depende del número de variables, redundancia, ruido y métrica de negocio.

6. Errores frecuentes de interpretación

- Confundir `max_features` con cantidad total de variables del dataset.

- Buscar el árbol individual más preciso dentro de un Random Forest.
- Interpretar una baja correlación como objetivo suficiente sin revisar desempeño.

7. Glosario específico

Término	Definición para estudio
Random Forest	Ensemble de árboles que combina bootstrap y selección aleatoria de variables por split.
Random subspace	Restricción aleatoria del conjunto de predictores candidatos.
max_features / mtry	Cantidad de variables que pueden competir en cada nodo.
Correlación entre árboles	Grado en que los árboles producen patrones de predicción similares.
Fuerza del árbol	Capacidad predictiva de un árbol individual.
Decorrelación	Reducción deliberada de similitud entre modelos del ensemble.

8. Puente hacia la simulación siguiente

Conexión. Una vez definido un bosque, queda decidir cuántos árboles son suficientes. La Simulación 10 compara la curva OOB y la validación externa para reconocer la convergencia del ensemble.

SIMULACIÓN 10 · BLOQUE III · BAGGING Y RANDOM FOREST

Número de árboles y error OOB

Archivo asociado: simulador_10_numero_arboles_oob.html

Objetivo. Analizar la convergencia de un Random Forest y usar OOB como estimación interna de desempeño sin confundir estabilización con corrección de sesgo.

Predicción OOB_i = promedio de árboles para los que i quedó fuera del bootstrap

1. Fundamento conceptual

Cada observación puede recibir una predicción OOB agregando solamente árboles que no la utilizaron para entrenarse. Al crecer el número de árboles, aumenta la cantidad de votos OOB disponibles por caso y disminuye la variación Monte Carlo del ensemble.

La simulación construye bosques con distintos valores de `n_estimators` y compara accuracy OOB contra una validación externa. Si ambas curvas se estabilizan en una zona similar, tenemos evidencia práctica de que agregar muchos más árboles probablemente no alterará sustancialmente la decisión.

La convergencia no significa que el modelo sea correcto. Un bosque puede estabilizarse alrededor de un desempeño mediocre si existe sesgo, variables deficientes, leakage, drift o una definición inadecuada del target. `n_estimators` controla la precisión del promedio, no repara el problema de modelado.

2. Qué controla la simulación

Control	Qué modifica	Qué observar
<code>n_estimators</code> (10 a 200)	Cantidad de árboles del bosque.	OOB accuracy, validación, cobertura OOB y estabilidad.
Restablecer	Vuelve a 70 árboles.	Punto intermedio útil para recorrer la curva hacia ambos lados.

3. Secuencia de uso recomendada

1. Comparar bosques pequeños, por ejemplo 10-30 árboles.
2. Aumentar el tamaño y observar cómo OOB y validación dejan de moverse de forma apreciable.
3. Verificar cobertura OOB: con pocos árboles algunos casos pueden tener pocos votos.
4. Elegir un tamaño que estabilice la métrica con un costo computacional razonable.

4. Ejemplo trabajado

El laboratorio genera 460 observaciones de seguros y reserva aproximadamente 28% para validación. Evalúa bosques de 10, 20, 30, 40, 50, 60, 70, 80, 100, 120, 150, 180 y 200 árboles, manteniendo `max_features = 2`, profundidad máxima 7 y tamaño mínimo de hoja 3. El valor inicial de 70 árboles permite comparar un punto ya relativamente estable con bosques más pequeños.

5. Cómo interpretar el resultado

- OOB y validación no tienen que coincidir exactamente; son estimaciones construidas de manera distinta.
- La cobertura OOB tiende a acercarse a 100% para el conjunto cuando existe un número suficiente de árboles.
- Elegir B mucho mayor puede ser razonable si el costo computacional es bajo, pero no necesariamente produce mejora material.

6. Errores frecuentes de interpretación

- Buscar un “número mágico” de árboles universal.
- Interpretar una curva plana como ausencia de sesgo.
- Optimizar `n_estimators` usando el test final.

7. Glosario específico

Término	Definición para estudio
n_estimators	Cantidad de árboles incluidos en el ensemble.
Error OOB	Error estimado con predicciones de árboles que no vieron cada observación.
Cobertura OOB	Proporción de casos con suficientes predicciones OOB disponibles.
Convergencia	Estabilización de la salida del ensemble al agregar más árboles.
Variación Monte Carlo	Variación debida al número finito de realizaciones aleatorias.
Costo computacional	Tiempo y recursos requeridos para entrenar, almacenar y predecir.

8. Puente hacia la simulación siguiente

Conexión. El número de árboles controla la estabilidad del promedio. Pero la varianza residual del ensemble está fuertemente condicionada por la correlación entre árboles. La Simulación 11 aísla ese trade-off mediante `max_features`.

SIMULACIÓN 11 · BLOQUE III · BAGGING Y RANDOM FOREST

max_features y correlación

Archivo asociado: simulador_11_max_features_correlacion.html

Objetivo. Estudiar de forma explícita el equilibrio entre fuerza de cada árbol y correlación de sus predicciones al variar max_features.

$$\text{Var(promedio)} \approx p\sigma^2 + (1 - p)\sigma^2/B$$

1. Fundamento conceptual

La reducción de varianza obtenida al promediar depende de dos elementos: la varianza de los modelos individuales y el grado en que se parecen entre sí. Cuando B es grande, el término asociado a la correlación p se vuelve el límite principal. Si p permanece alta, seguir agregando árboles ofrece menos reducción adicional.

max_features actúa sobre esa correlación. Con un valor muy pequeño, muchos nodos deben dividirse sin disponer de la variable más informativa, lo que produce diversidad pero debilita el árbol promedio. Con un valor muy grande, los árboles disponen de más señal, pero tienden a usar reglas similares.

Por eso el mejor punto suele ser intermedio. El simulador no pretende enseñar que max_features = 2 sea universal; muestra cómo diagnosticar el compromiso observando accuracy del ensemble, accuracy del árbol medio, correlación y OOB.

2. Qué controla la simulación

Control	Qué modifica	Qué observar
max_features = 1...6	Cantidad de variables candidatas por split.	Accuracy del ensemble, correlación media, accuracy del árbol medio y OOB.
Mejor validación	Muestra el máximo de accuracy de validación en esta muestra.	Que el óptimo depende de los datos y no de una regla fija.

3. Secuencia de uso recomendada

1. Comparar max_features = 1 contra max_features = 6.
2. Observar que en un extremo aumenta diversidad y en el otro fuerza individual.
3. Buscar la zona intermedia donde el ensemble combina ambas ventajas.
4. Usar OOB como evidencia adicional, no como única métrica.

4. Ejemplo trabajado

La simulación utiliza 460 observaciones y seis variables. Para cada max_features entre 1 y 6 entrena un bosque de 70 árboles con profundidad máxima 7 y tamaño mínimo de hoja 3. La correlación se calcula sobre las predicciones de 30 árboles individuales en validación. El análisis muestra por qué “árboles más fuertes” y “mejor bosque” no son sinónimos.

5. Cómo interpretar el resultado

- Reducir p puede mejorar el promedio aunque baje ligeramente el accuracy del árbol individual.
- Si max_features es demasiado pequeño, el ensemble puede perder señal y aumentar sesgo.
- Si es demasiado grande, la diversidad cae y el beneficio del promedio se limita.

6. Errores frecuentes de interpretación

- Optimizar solo accuracy del árbol medio.

- Interpretar la fórmula como identidad exacta en cualquier contexto.
- Suponer que menor correlación siempre es mejor sin mirar la fuerza de los componentes.

7. Glosario específico

Término	Definición para estudio
ρ (rho)	Correlación media aproximada entre predicciones o errores de árboles.
σ^2	Varianza típica de un árbol individual en la intuición del ensemble.
Fuerza-diversidad	Compromiso entre capacidad predictiva individual y diferencia entre modelos.
Árbol medio	Resumen del desempeño promedio de los componentes individuales.
Límite de varianza	Parte de la varianza del ensemble que no desaparece simplemente aumentando B cuando la correlación es positiva.

8. Puente hacia la simulación siguiente

Conexión. Después de entrenar un bosque robusto aparece otra pregunta: ¿qué variables utiliza y en qué sentido son “importantes”? La Simulación 12 compara dos definiciones que suelen confundirse: MDI y permutation importance.

SIMULACIÓN 12 · BLOQUE IV · INTERPRETABILIDAD

MDI vs. permutation importance

Archivo asociado: simulador_12_feature_importance.html

Objetivo. Comparar dos nociones de importancia de variables, identificar qué pregunta responde cada una y evitar interpretaciones causales indebidas.

MDI: reducción acumulada de impureza | **Permutation: AUC_base - AUC_permutada**

1. Fundamento conceptual

Mean Decrease Impurity (MDI) es una importancia interna del bosque. Acumula cuánto contribuyen los splits de una variable a reducir impureza, ponderando por el tamaño de los nodos. Es rápida y está disponible como parte natural del entrenamiento, pero puede favorecer variables con muchas oportunidades de corte y repartir la señal de manera poco intuitiva cuando existen predictores redundantes.

Permutation importance formula una pregunta distinta: si rompo la asociación de una variable con el resto de los datos, ¿cuánto empeora el desempeño fuera de muestra? El laboratorio mide la caída de AUC después de permutar una columna de validación. Esa aproximación está más cerca de una noción de dependencia predictiva operacional.

Ninguna de las dos métricas es causal. Una variable puede ser altamente predictiva por ser proxy de otra, por reflejar selección previa o por compartir información redundante. La interpretación debe incluir conocimiento del proceso y análisis de estabilidad.

2. Qué controla la simulación

Control	Qué modifica	Qué observar
Número de árboles B	Cambia la estabilidad del Random Forest y de sus importancias.	AUC base, top MDI, top permutation y coincidencia de rankings.

3. Secuencia de uso recomendada

1. Entrenar el bosque con el valor inicial.
2. Comparar la tabla MDI vs. caída de AUC para las seis variables.
3. Aumentar B y verificar si los rankings se estabilizan.
4. Identificar variables correlacionadas y anticipar por qué los métodos pueden discrepar.

4. Ejemplo trabajado

El conjunto sintético de seguros contiene 620 observaciones con seis variables: Monto, Historial, Edad, Canal, Monto correlacionado y Ruido. Se usa 65% para entrenamiento y 35% para validación. El bosque inicial contiene 70 árboles, max_features = 2, profundidad máxima 7 y hojas mínimas de 3 casos. MDI se obtiene desde los splits; permutation se calcula rompiendo cada variable en validación y observando la caída de AUC.

5. Cómo interpretar el resultado

- MDI explica uso interno del predictor dentro de la estructura aprendida.
- Permutation explica cuánto depende el desempeño de la información de una variable en la muestra de evaluación.
- Si dos variables contienen información similar, una puede sustituir a la otra y la caída individual por permutación puede ser pequeña.

6. Errores frecuentes de interpretación

- Leer “importancia” como efecto causal.
- Comparar importancias obtenidas en train con métricas fuera de muestra sin distinguir su origen.
- Eliminar automáticamente variables con permutation importance baja sin revisar redundancia.

7. Glosario específico

Término	Definición para estudio
MDI	Importancia basada en reducción media/acumulada de impureza dentro de árboles.
Permutation importance	Importancia medida por pérdida de desempeño al permutar una característica.
AUC	Métrica de ranking que resume la separación entre clases a través de thresholds.
Proxy	Variable que transporta información relacionada con otra característica o proceso.
Importancia predictiva	Contribución de una variable a la predicción, sin implicar causalidad.
Ranking de variables	Orden relativo según una definición específica de importancia.

8. Puente hacia la simulación siguiente

Conexión. La discrepancia entre importancias se vuelve especialmente clara cuando dos predictores comparten información. La Simulación 13 manipula directamente la correlación para mostrar cómo la redundancia puede esconder relevancia individual.

SIMULACIÓN 13 · BLOQUE IV · INTERPRETABILIDAD

Variables correlacionadas

Archivo asociado: simulador_13_variables_correlacionadas.html

Objetivo. Comprender cómo la correlación y la redundancia predictiva afectan permutation importance y por qué conviene evaluar grupos de variables relacionadas.

Información redundante → importancia individual puede ↓ aunque el grupo siga siendo esencial

1. Fundamento conceptual

Si X_1 y X_2 contienen casi la misma señal, un modelo puede utilizar una como sustituta de la otra. Al permutar solamente X_1 , X_2 todavía conserva gran parte de la información y el AUC puede caer poco. Sería incorrecto concluir que X_1 “no importa”. La métrica está midiendo importancia condicional al resto de predictores disponibles.

La simulación genera X_1 como señal, X_2 como versión cada vez más correlacionada con X_1 y una tercera variable de ruido. El control p aproxima el grado de redundancia. Además de permutar cada variable por separado, se permutan X_1 y X_2 conjuntamente para revelar la importancia del grupo.

Este problema es central en interpretación de modelos tabulares: rankings de variables no deben leerse de manera aislada. Correlación, variables duplicadas, distintas codificaciones de la misma señal y proxies pueden redistribuir la importancia sin alterar demasiado el desempeño global.

2. Qué controla la simulación

Control	Qué modifica	Qué observar
Correlación aproximada p (0 a 0,98)	Controla cuánto comparte X_2 la señal latente de X_1 .	Caída de AUC al permutar X_1 , X_2 y ambas conjuntamente.

3. Secuencia de uso recomendada

1. Comenzar con p bajo y comparar las importancias individuales.
2. Aumentar gradualmente la correlación.
3. Observar si disminuye la caída por permutar una sola variable.
4. Comparar con la permutación conjunta X_1+X_2 .

4. Ejemplo trabajado

El laboratorio genera 700 observaciones y usa un valor inicial $p = 0,84$. X_1 contiene la señal, X_2 comparte gran parte de ella y una tercera variable es ruido. El Random Forest utiliza 80 árboles. Cuando la correlación es alta, la caída de AUC al romper X_1 o X_2 por separado puede ser modesta, mientras que romper ambas a la vez revela una pérdida mucho mayor.

5. Cómo interpretar el resultado

- Permutation importance es dependiente del conjunto de variables presentes.
- Una importancia individual baja no implica necesariamente irrelevancia sustantiva.
- La permutación conjunta ayuda a evaluar grupos redundantes, aunque tampoco constituye evidencia causal.

6. Errores frecuentes de interpretación

- Eliminar una variable correlacionada solo porque su importancia individual es baja.
- Interpretar correlación como causalidad.

- Ignorar que dos variables pueden ser proxies intercambiables para el modelo.

7. Glosario específico

Término	Definición para estudio
Correlación	Medida de asociación entre dos variables; no implica causalidad.
Redundancia predictiva	Situación en la que varias variables transportan información similar para predecir y.
Permutación conjunta	Ruptura simultánea de varias columnas para medir la dependencia del modelo respecto del grupo.
Importancia condicional	Importancia de una variable dada la presencia de las demás.
Sustitución	Capacidad de un predictor de compensar la pérdida informativa de otro.
Grupo de variables	Conjunto de predictores que conviene interpretar de manera conjunta por su relación estructural.

8. Puente hacia la simulación siguiente

Conexión. Las importancias indican qué variables afectan el desempeño, pero no muestran la forma del efecto aprendido. La Simulación 14 avanza desde “qué importa” hacia “cómo cambia la predicción”: PDP e ICE.

SIMULACIÓN 14 · BLOQUE IV · INTERPRETABILIDAD

PDP e ICE

Archivo asociado: simulador_14_pdp_ice.html

Objetivo. Distinguir efectos promedio de trayectorias individuales y detectar heterogeneidad o interacciones que pueden quedar ocultas por un PDP global.

$$\text{PDP}(x) = E[f(x, X_{-j})] \quad | \quad \text{ICE}_i(x) = f(x, X_{-j}, i)$$

1. Fundamento conceptual

Partial Dependence Plot (PDP) pregunta cómo cambia, en promedio, la predicción del modelo cuando se fija una variable en distintos valores y se promedian las predicciones sobre el resto de las características observadas. Es una descripción global del comportamiento del modelo, no una relación causal.

Individual Conditional Expectation (ICE) realiza el mismo experimento caso por caso. Cada curva conserva las demás características de una observación y modifica solo la variable estudiada. Si las curvas son aproximadamente paralelas, el PDP suele resumir bien el patrón; si se cruzan o tienen pendientes muy diferentes, el promedio puede estar ocultando interacciones o subgrupos.

La simulación incluye un mecanismo generador donde el efecto de Monto interactúa con Antigüedad. Por eso es especialmente útil comparar el PDP azul con las curvas ICE grises y observar la dispersión entre trayectorias.

2. Qué controla la simulación

Control	Qué modifica	Qué observar
Variable	Selecciona Monto, Antigüedad o Historial.	Forma del PDP y heterogeneidad de ICE.
Curvas ICE (3 a 20)	Cantidad de observaciones individuales mostradas.	Dispersión y presencia de subgrupos o interacciones.

3. Secuencia de uso recomendada

1. Seleccionar Monto y observar PDP más ICE.
2. Aumentar el número de curvas individuales.
3. Comparar si las trayectorias son paralelas o divergentes.
4. Repetir con Antigüedad e Historial y comparar rango del PDP y dispersión ICE.

4. Ejemplo trabajado

El laboratorio genera 650 observaciones con tres variables y entrena un Random Forest de 90 árboles. La partición utiliza 68% para entrenamiento. El valor inicial estudia “Monto” y muestra 10 curvas ICE. Para cada uno de 21 valores de la grilla, se reemplaza Monto y se recalcula la probabilidad; el PDP es el promedio de esas predicciones y la dispersión resume cuánto se alejan las curvas individuales de ese promedio.

5. Cómo interpretar el resultado

- PDP describe al modelo, no necesariamente al proceso causal real.
- ICE permite detectar heterogeneidad que un promedio puede ocultar.
- Con variables muy correlacionadas, fijar valores artificialmente puede crear combinaciones poco realistas; la interpretación debe ser prudente.

6. Errores frecuentes de interpretación

- Leer PDP como “si aumento X, causará Y”.
- Mirar solo el promedio cuando las ICE son heterogéneas.
- Ignorar regiones de X con poca densidad de datos.

7. Glosario específico

Término	Definición para estudio
PDP	Curva de dependencia parcial que resume el efecto promedio de una variable sobre la predicción.
ICE	Curva individual que muestra cómo cambia la predicción de un caso al variar una característica.
Heterogeneidad	Diferencias entre respuestas individuales al variar una característica.
Interacción	Dependencia del efecto de una variable respecto de otra.
Efecto del modelo	Patrón aprendido por el predictor; no equivale a efecto causal.
Extrapolación	Evaluación en combinaciones de variables raras o no representativas de los datos observados.

8. Puente hacia la simulación siguiente

Conexión. Después de explorar árboles paralelos y su interpretación, la Simulación 15 presenta una filosofía de ensemble diferente: Boosting, donde los modelos se construyen secuencialmente para corregir errores acumulados.

SIMULACIÓN 15 · BLOQUE V · BOOSTING Y DECISIÓN

Gradient Boosting

Archivo asociado: simulador_15_boosting.html

Objetivo. Comprender el aprendizaje secuencial de boosting y el trade-off entre learning_rate, número de etapas, capacidad y sobreajuste.

$$F_m(x) = F_{(m-1)}(x) + \eta h_m(x)$$

1. Fundamento conceptual

Gradient Boosting construye un modelo aditivo. Comienza con una predicción base y agrega pequeños learners de manera secuencial. Cada nueva etapa se ajusta a los errores o pseudo-residuos que el conjunto acumulado todavía no explica. A diferencia de Bagging, las etapas no son independientes: la etapa m depende del estado alcanzado en m-1.

El learning_rate η controla cuánto pesa cada corrección. Un valor pequeño hace avances más conservadores y suele requerir más etapas; un valor grande aprende más rápido, pero puede aumentar la sensibilidad y el riesgo de sobreajuste. Por eso n_estimators y learning_rate deben analizarse conjuntamente.

La simulación grafica AUC de train y validación a lo largo de las etapas. La lógica de early stopping consiste en detener el entrenamiento cuando la métrica de validación deja de mejorar, en lugar de continuar agregando capacidad solo porque train sigue avanzando.

2. Qué controla la simulación

Control	Qué modifica	Qué observar
n_estimators (5 a 100)	Cantidad máxima de correcciones secuenciales.	Trayectoria de AUC y brecha train-validación.
learning_rate (0,03 a 0,50)	Tamaño del aporte de cada etapa.	Velocidad de aprendizaje, underfitting y posible sobreajuste.

3. Secuencia de uso recomendada

1. Probar pocas etapas con learning_rate bajo y observar underfitting.
2. Aumentar n_estimators manteniendo η fijo.
3. Aumentar η y comparar cuántas etapas necesita el modelo.
4. Buscar el punto donde validación deja de mejorar aunque train continúe subiendo.

4. Ejemplo trabajado

El laboratorio usa 320 observaciones de entrenamiento y 800 de validación, con 16% de ruido. El estado inicial entrena 40 etapas con learning_rate = 0,12 y learners pequeños. La curva se calcula por etapas para mostrar cómo evoluciona el ranking predictivo. No se busca un par de hiperparámetros universal, sino comprender que “muchas etapas” solo tiene sentido en relación con el tamaño de paso.

5. Cómo interpretar el resultado

- Un learning_rate menor suele necesitar más n_estimators.
- La brecha train-validación es una señal útil, pero el punto de parada debe definirse con una métrica coherente con el problema.
- Boosting puede reducir sesgo con gran eficiencia, aunque requiere regularización y monitoreo cuidadosos.

6. Errores frecuentes de interpretación

- Tratar los árboles de boosting como independientes.
- Aumentar `n_estimators` sin mirar validación.
- Comparar `learning_rate` aislado del número de etapas.

7. Glosario específico

Término	Definición para estudio
Boosting	Familia de ensembles secuenciales donde cada etapa corrige al modelo acumulado.
Gradient Boosting	Boosting que avanza siguiendo el gradiente de una función de pérdida.
learning_rate	Factor de shrinkage que escala la contribución de cada nuevo learner.
n_estimators	Número de etapas o learners agregados.
Pseudo-residuo	Señal de error que guía la siguiente corrección en boosting.
Early stopping	Detención del entrenamiento cuando validación deja de mejorar.
Modelo aditivo	Modelo construido como suma progresiva de contribuciones.

8. Puente hacia la simulación siguiente

Conexión. La última simulación deja de preguntar solamente “qué modelo predice mejor” y obliga a decidir. Combina modelo, threshold y costos para mostrar que una buena métrica de ranking no determina por sí sola la mejor política operativa.

SIMULACIÓN 16 · BLOQUE V · BOOSTING Y DECISIÓN

Decision Lab: modelo, threshold y costos

Archivo asociado: simulador_16_decision_lab.html

Objetivo. Integrar modelado y decisión comparando árbol podado, Random Forest y Boosting bajo un mismo test y una función de costos explícita.

$$\text{Costo total} = \text{FP} \cdot C_{\text{FP}} + \text{FN} \cdot C_{\text{FN}}$$

1. Fundamento conceptual

Un modelo probabilístico produce scores o probabilidades; una organización necesita transformar esos scores en acciones. El threshold es la regla que separa los casos intervenidos de los no intervenidos. Cambiarlo modifica simultáneamente falsos positivos, falsos negativos y volumen operativo.

El AUC evalúa capacidad de ranking y no depende de un threshold particular. El costo, en cambio, depende completamente de la política de decisión y de cuánto vale cada tipo de error. Si un falso negativo es muy costoso, puede convenir bajar el threshold para capturar más positivos, aceptando más falsos positivos. Si la capacidad de revisión es limitada, el problema puede expresarse también como top-K o presupuesto operativo.

La simulación compara tres familias de modelos sobre el mismo test y permite modificar threshold, costo FP y costo FN. La lección final del módulo es que seleccionar un modelo no es elegir la mayor métrica abstracta: es diseñar una política defendible que combine validación, calibración, costos, capacidad, estabilidad, latencia, explicabilidad y gobernanza.

2. Qué controla la simulación

Control	Qué modifica	Qué observar
Modelo	Árbol podado, Random Forest o Boosting.	AUC y estructura de errores en el mismo test.
Threshold (0,10 a 0,90)	Convierte probabilidad en acción.	FP, FN, costo total y cantidad de acciones positivas.
Costo FP (1 a 50)	Costo de intervenir un negativo.	Cómo penalizar revisiones innecesarias.
Costo FN (10 a 250)	Costo de omitir un positivo real.	Cómo cambia el threshold económicamente conveniente.

3. Secuencia de uso recomendada

1. Comparar AUC de los tres modelos sin tocar el threshold.
2. Mantener modelo fijo y recorrer thresholds.
3. Aumentar C_{FN} y observar cómo se desplaza el mínimo de costo.
4. Aumentar C_{FP} y observar la presión hacia políticas más conservadoras.
5. Comparar modelos con el mismo threshold y luego permitir que cada uno tenga una política optimizada.

4. Ejemplo trabajado

El laboratorio genera 900 observaciones de seguros y utiliza 65% para entrenamiento. El árbol se poda con $\alpha = 0,018$; Random Forest usa 90 árboles; Boosting usa 60 etapas con $\text{learning_rate} = 0,12$. El estado inicial selecciona Random Forest, $\text{threshold} = 0,50$, $\text{costo FP} = 8$ y $\text{costo FN} = 120$. La curva de costo

marca en verde el threshold de menor costo dentro de la grilla y en amarillo la política actual. Cambiar los costos puede cambiar tanto el threshold conveniente como el modelo de menor costo.

5. Cómo interpretar el resultado

- AUC alto no garantiza menor costo en un punto operativo concreto.
- Threshold y modelo son decisiones separadas: un mismo modelo puede soportar múltiples políticas.
- La función de costos debe venir del proceso real y no inventarse solo para favorecer un modelo.
- Antes de desplegar también deben revisarse calibración, latencia, drift, equidad, capacidad y circuitos de revisión humana.

6. Errores frecuentes de interpretación

- Fijar threshold = 0,5 por costumbre.
- Elegir modelo exclusivamente por AUC.
- Comparar costos usando poblaciones o thresholds inconsistentes.
- Confundir costo económico con función de pérdida de entrenamiento.

7. Glosario específico

Término	Definición para estudio
Threshold	Punto de corte que transforma un score probabilístico en una acción binaria.
Falso positivo (FP)	Caso marcado positivo cuando la clase real es negativa.
Falso negativo (FN)	Caso no marcado aunque la clase real es positiva.
Costo esperado	Valor económico u operativo asociado a la combinación de errores y acciones.
AUC	Capacidad global de ranking independiente de un threshold específico.
Política de decisión	Regla que transforma scores en acciones bajo costos y restricciones.
Capacidad operativa	Cantidad de casos que la organización puede revisar o intervenir.
Gobernanza	Controles, responsables y reglas que hacen auditable el uso del modelo.

8. Puente hacia la simulación siguiente

Conexión. Con esta simulación se cierra el recorrido: del split local de CART a una política de decisión completa. El modelo deja de ser un objeto aislado y pasa a formar parte de un sistema de decisión que debe validarse, interpretarse y monitorearse.

Cierre integrador: del split a la decisión

El recorrido de las 16 simulaciones puede resumirse como una cadena lógica. CART comienza con una decisión local: elegir una variable y un umbral que reduzcan impureza. Esa capacidad genera una partición interpretable del espacio, pero al aumentar complejidad aparecen sobreajuste e inestabilidad. La poda intenta regularizar el árbol individual; Bagging adopta otra estrategia y promedia muchos árboles construidos sobre muestras bootstrap.

Random Forest mejora la diversidad del ensemble restringiendo las variables disponibles en cada nodo. A partir de allí, `n_estimators` y `max_features` deben leerse como controles de estabilidad, fuerza y correlación, no como números mágicos. OOB ofrece una evaluación interna muy útil, pero no reemplaza el diseño de validación cuando existe estructura temporal, agrupamientos, selección muestral u otras dependencias.

Una vez que el modelo predice, comienza la etapa de interpretación. MDI y permutation importance responden preguntas distintas; las variables correlacionadas muestran por qué un ranking aislado puede engañar; PDP e ICE permiten estudiar la forma del efecto aprendido y la heterogeneidad entre casos. Ninguna de estas herramientas transforma asociación predictiva en causalidad.

Boosting introduce una filosofía secuencial: en vez de promediar árboles independientes, agrega correcciones sobre el modelo acumulado. Finalmente, Decision Lab recuerda que el objetivo real no es maximizar una métrica académica, sino convertir predicciones en acciones defendibles. Modelo, threshold, costos, capacidad operativa, calibración, estabilidad y gobernanza forman parte de una misma decisión.

Glosario general del módulo

Término	Definición para estudio
Accuracy	Proporción de predicciones de clase correctas. Puede ser poco informativa ante clases muy desbalanceadas o costos asimétricos.
AUC / ROC-AUC	Probabilidad de que un positivo reciba un score mayor que un negativo elegido al azar; resume ranking y no fija un threshold operativo.
Bagging	Bootstrap Aggregating: entrenamiento de múltiples modelos sobre muestras bootstrap y agregación de sus predicciones.
Bootstrap	Remuestreo con reemplazo que genera muestras alternativas del conjunto de entrenamiento.
Calibración	Correspondencia entre probabilidades predichas y frecuencias observadas.
CART	Classification and Regression Trees; algoritmo de partición recursiva greedy usado para árboles de clasificación y regresión.
ccp_alpha	Parámetro de poda costo-complejidad que penaliza el número de hojas.
Correlación entre árboles	Similitud de las predicciones o errores de los componentes del ensemble.
Costo esperado	Traducción de resultados de clasificación a consecuencias económicas u operativas.
Drift	Cambio en distribuciones o relaciones del

Término	Definición para estudio
	problema después del despliegue.
Early stopping	Detención del entrenamiento cuando validación deja de mejorar.
Ensemble	Sistema que combina varios modelos para producir una salida agregada.
Entropía	Medida de incertidumbre de la distribución de clases de un nodo.
Falso negativo	Positivo real que la política no marca como positivo.
Falso positivo	Negativo real que la política marca como positivo.
Ganancia de impureza	Disminución de impureza conseguida por una división.
Gini	Criterio de impureza habitual en árboles de clasificación.
ICE	Individual Conditional Expectation; curvas individuales del efecto aprendido por el modelo.
Importancia de variables	Conjunto de métricas que cuantifican distintos aspectos de dependencia predictiva de los predictores.
In-bag	Casos incluidos al menos una vez en el bootstrap de un árbol.
Learning rate	Tamaño de paso que regula la contribución de cada etapa en boosting.
max_depth	Profundidad máxima permitida del árbol.
max_features	Cantidad de variables candidatas por split en Random Forest.
MDI	Mean Decrease Impurity; importancia interna basada en reducción de impureza.
min_samples_leaf	Mínimo de observaciones permitido en una hoja terminal.
n_estimators	Cantidad de árboles o etapas de un ensemble.
OOB	Out-of-Bag; observaciones no incluidas en el bootstrap de un árbol.
Overfitting	Exceso de ajuste a la muestra de entrenamiento con deterioro de generalización.
PDP	Partial Dependence Plot; efecto promedio del modelo al variar una característica.
Permutation importance	Caída de desempeño al romper una variable mediante permutación fuera de muestra.
Poda	Reducción de ramas para controlar complejidad

Término	Definición para estudio
	del árbol.
Random Forest	Ensemble que combina bootstrap y subespacios aleatorios de variables.
Regularización	Conjunto de restricciones o penalizaciones destinadas a controlar complejidad y mejorar generalización.
Sesgo-varianza	Trade-off entre rigidez sistemática y sensibilidad a la muestra.
Split	Regla que divide un nodo en dos subconjuntos.
Threshold	Punto de corte que transforma un score en una decisión de clase.
Validación	Evaluación utilizada para comparar configuraciones sin contaminar el test final.
Varianza	Sensibilidad del modelo a cambios en los datos de entrenamiento.

Checklist para leer cualquier modelo del módulo

- ¿Cuál es la población objetivo y qué significa la clase positiva?
- ¿Qué partición de datos se utilizó para entrenar, validar y evaluar?
- ¿La complejidad fue elegida fuera de muestra?
- ¿La métrica coincide con el objetivo del problema y el desbalance de clases?
- ¿El score está calibrado si se interpreta como probabilidad?
- ¿Qué threshold o regla operativa convierte scores en acciones?
- ¿Cuánto cuestan FP y FN y qué capacidad de intervención existe?
- ¿Las importancias se interpretan como predicción y no como causalidad?
- ¿Se revisaron redundancia, interacciones y estabilidad por segmentos?
- ¿Existe un plan de monitoreo para drift, desempeño, costos y cambios de prevalencia?

Idea final. Un modelo de Machine Learning no termina cuando produce un score. La calidad técnica se vuelve decisión defendible recién cuando el modelo fue validado, interpretado, conectado con costos y restricciones reales y acompañado por un esquema de monitoreo.