

Boosting, interpretación y decisión

De ensembles secuenciales a explicaciones defendibles y decisiones operativas con costo, estabilidad y latencia.


Gradient boosting

PDP / ICE

Permutation importance

SHAP

Costos y monitoreo



La tercera pieza del módulo

PPT 01 explicó árboles; PPT 02 explicó bosques. Ahora pasamos a modelos secuenciales e interpretación profesional.

01

Boosting

Por qué aprender árboles en secuencia puede mejorar sesgo y desempeño.

02

Regularizar

Learning rate, profundidad, subsampling y early stopping.

03

Interpretar

Importancia, permutation, PDP, ICE y SHAP con límites claros.

04

Decidir

Valor, latencia, calibración, monitoreo y reporte final.

Idea central


Un modelo más preciso no es automáticamente una mejor decisión. Debe ser validado, explicado y operado.

Random Forest y boosting: agregación y secuencia

Random Forest reduce varianza; boosting construye una secuencia que ataca errores residuales.

Random Forest


Muchos árboles en paralelo



Objetivo dominante: bajar varianza

Boosting

Árboles pequeños en secuencia



cada paso corrige errores del anterior

Objetivo: mejorar la pérdida con regularización

La intuición: aprender lo que falta

En regresión, el residuo muestra la parte que el modelo aún no explicó; en clasificación, el gradiente negativo cumple una función análoga.

Modelo inicial




Errores residuales



$$\text{residuo} = y - F_0(x)$$

Árbol corrector



el árbol aprende una corrección simple

Boosting como modelo aditivo

El modelo final no es un único árbol: es la suma controlada de muchas correcciones pequeñas.

$$F_M(x) = F_0(x) + \nu \cdot \sum_{m=1}^M \gamma_m h_m(x)$$

 F_0

Modelo inicial

Una constante en la escala del modelo, como media o log-odds iniciales.

 $h_m(x)$

Árbol débil

Árbol pequeño: baja profundidad, alta regularización.

 γ_m

Peso de la corrección

Cuánto aporta cada árbol al modelo acumulado.

 ν

Learning rate

Encoge cada paso para ganar estabilidad.

Traducción didáctica

Aprender de a pasos chicos suele generalizar mejor que intentar corregir todo con un árbol grande.

La función de pérdida define qué significa “error”

Gradient boosting no corrige “errores” en abstracto: optimiza una pérdida concreta.

Regresión

$$L(y, F) = (y - F(x))^2$$

Los árboles siguientes aproximan residuos.

Clasificación

$$L = -[y \log(p) + (1-y) \log(1-p)]$$

Los árboles aproximan el gradiente negativo de la pérdida logística.

Decisión

$$\text{Valor} = \text{beneficio}(\text{TP}) - \text{costo}(\text{FP}, \text{FN})$$

La pérdida estadística se traduce luego a política operativa.

Los árboles del boosting no deberían ser demasiado fuertes


El poder surge de combinar muchos árboles simples, no de dejar que cada árbol memorice el entrenamiento.

Profundidad 1



mayor sesgo, menor complejidad

Profundidad 2-3



captura interacciones de orden bajo

Árbol profundo




riesgo de memorizar ruido

Regla práctica

En boosting, primero controle profundidad, learning rate y early stopping. Después piense en más árboles.

Learning rate $\times$ número de árboles

Un learning rate bajo suele requerir más árboles, pero puede producir un camino de aprendizaje más estable.



Lectura didáctica

v pequeño: cada árbol aporta poco; reduce riesgo de saltar hacia ruido.


v grande: aprende rápido, pero puede sobreajustar antes.

No compare modelos por número de árboles sin mirar learning rate.

Early stopping define cuándo dejar de agregar correcciones.

Early stopping: detenerse antes de memorizar

El modelo puede seguir mejorando en entrenamiento mientras la validación empieza a deteriorarse.



Protocolo

Separar validación o usar CV.
Entrenar aumentando iteraciones.
Guardar el punto de menor pérdida fuera de muestra.
No elegir el punto mirando el test final.

Criterio Detener cuando agregar árboles ya no mejora la decisión.

Palancas de control del boosting

Cada parámetro regula una forma distinta de complejidad; no son perillas independientes.

Profundidad

Interacciones por árbol

max_depth

Learning rate

Tamaño de cada paso

learning_rate

Iteraciones

Cantidad de correcciones

n_estimators

Subsampling

Ruido regularizador

subsample

Hojas mínimas

Estabilidad local

min_samples_leaf

Early stopping

Freno externo

n_iter_no_change

AdaBoost y Gradient Boosting

AdaBoost repondera observaciones; Gradient Boosting aproxima el gradiente negativo de una pérdida.

AdaBoost

Aumenta peso de casos mal clasificados.
Combina clasificadores débiles ponderados.
Es didácticamente excelente para ver “foco en errores”.
Puede ser sensible a ruido y outliers.

Gradient Boosting

Optimiza una pérdida diferenciable.
Agrega árboles que aproximan gradientes negativos o residuos.
Es más flexible: regresión, clasificación y pérdidas diversas.
Base conceptual de implementaciones modernas.

Gradient boosting moderno

Las bibliotecas modernas aceleran entrenamiento, manejan grandes volúmenes y agregan regularización sofisticada.

01

HistGradientBoosting

scikit-learn · histogramas,
integración simple

02

XGBoost

ecosistema ML ·
regularización, paralelismo,
producción

03

LightGBM

alto volumen · leaf-wise
growth, velocidad

04

CatBoost

categorías · tratamiento
robusto de variables
categorías

Para el curso, la prioridad no es memorizar APIs: es entender el patrón común de modelo aditivo, regularización, validación y decisión.


Random Forest vs Boosting

La elección depende del objetivo: estabilidad, calibración, costo de error, explicación y operación.

Criterio	Random Forest	Boosting
Estrategia	paralelo / promedio	secuencial / corrección
Fortaleza típica	varianza y estabilidad	sesgo y precisión
Riesgo	importancia sesgada / tamaño	sobreajuste si no se frena
Control clave	max_features, n_estimators	learning_rate, early stopping
Lectura operativa	robusto y simple de operar	potente, requiere más cuidado

Buen ranking no implica buena probabilidad

Un modelo puede ordenar muy bien los casos riesgosos y aun así producir probabilidades demasiado optimistas o conservadoras.



Por qué importa

El threshold se elige sobre probabilidades estimadas.
Costos y capacidad dependen de cuántos casos serán positivos reales.
Puede calibrarse con Platt scaling o isotonic regression.
La calibración se evalúa fuera de muestra.

El modelo predice; la organización decide

La predicción de riesgo no es todavía una acción: falta elegir política.



Score: probabilidad o ranking producido por el modelo.
Threshold: punto que convierte score en acción.
Capacidad: cuántos casos se pueden revisar o intervenir.
Resultado: valor económico y consecuencias operativas.

Importancia interna: rápida, útil y peligrosa

Los árboles registran cuánto redujo impureza cada variable durante el entrenamiento.



Precauciones

Sesgo hacia variables continuas o con muchos cortes posibles.
Puede repartir importancia entre variables correlacionadas.
Mide uso predictivo, no causalidad.
Debe contrastarse fuera de muestra.

Permutation importance: romper una variable y medir la caída

Si permutar una variable destruye el desempeño, esa variable era importante para el modelo validado.




$$\text{Importancia}(X_j) = \text{score_base} - \text{score_permutado}(X_j)$$

Calcular en datos reservados. Si guía selección de variables, conservar un test independiente.

Variables correlacionadas: cuando la importancia engaña

Si dos variables contienen información parecida, romper una puede no afectar mucho porque la otra todavía sostiene el modelo.




Lectura correcta

Baja importancia individual no significa irrelevancia total.
La información puede estar duplicada.
Conviene analizar grupos de variables, estabilidad y dominio.
Evitar conclusiones causales a partir de rankings.

PDP: efecto promedio del modelo

Pregunta: si movemos una variable y promediamos sobre todos los casos, ¿cómo cambia la predicción media del modelo?




Fortalezas y límites

- Muy útil para comunicar dirección promedio.
- Puede ocultar heterogeneidad de subgrupos.
- Puede mostrar regiones con pocos datos reales.
- Es descripción del modelo, no prueba causal.

ICE: ver individuos antes de promediar

ICE muestra si todos los casos siguen la misma relación o si el promedio esconde historias distintas.



Cuándo usarlo

- Para detectar interacciones.
- Para explicar por qué el promedio no alcanza.
- Para ver subgrupos con sensibilidad diferente.
- Para controlar extrapolación visual.

SHAP: explicación local como suma de contribuciones

SHAP atribuye la diferencia respecto de una referencia. La suma depende de la escala explicada.

predicción base

riesgo final



Ejemplo ilustrativo en escala de probabilidad: base 0,31 y predicción 0,76.

Límites

Explica el modelo, no el mundo.
Puede ser sensible a correlaciones.
Requiere consistencia con validación.
Debe traducirse a lenguaje de decisión.

Una explicación también debe ser estable

No basta con explicar un modelo; hay que revisar si la explicación se sostiene al cambiar muestra, fold o período.

Fold 1

monto

zona

edad

Fold 2

monto

edad

zona

Fold 3

monto

canal

zona

Período nuevo

monto

zona

antigüedad

Señal fuerte

Una variable importante en todos los folds merece más confianza que una que aparece solo por azar.

Seleccionar modelos sin contaminar la evidencia

El test final no es una herramienta de tuning: es una auditoría posterior.



Error frecuente Probar 40 configuraciones y reportar el mejor resultado del test como si fuera evidencia independiente.

Optimizar con presupuesto, no por ansiedad

El objetivo es encontrar una configuración suficientemente buena y estable, no agotar combinaciones sin control.

01

Random search

cubre más espacio útil que
grilla ingenua

02

CV estratificada

mantiene prevalencia por
fold

03

Early stopping

reduce costo y sobreajuste

04

Budget explícito

tiempo, iteraciones y
semilla documentados

Entrega profesional Reportar rango explorado, criterio de selección, variación por folds y costo computacional.

La latencia también es una variable de decisión

Comparación conceptual: la latencia debe medirse en el entorno real de operación.



Preguntas operativas

- ¿Se predice en lote o en tiempo real?
- ¿Cuántos casos por hora?
- ¿Quién explica el resultado?
- ¿Qué pasa si el modelo falla?

Métricas técnicas → valor económico

La matriz de confusión se transforma en dinero, riesgo o capacidad utilizada.




$$\text{Valor} = b \cdot \text{TP} - c_{\text{FP}} \cdot \text{FP} - c_{\text{FN}} \cdot \text{FN} - c_{\text{op}} \cdot \text{acciones}$$

Un FN puede costar más que un FP.
La capacidad limita cuántas acciones se pueden tomar.
El threshold óptimo cambia cuando cambian costos o prevalencia.

Caso integrador: priorizar siniestros para revisión

La aseguradora no compra AUC: compra mejor asignación de analistas, menor fraude no detectado y control de falsos positivos.



Pregunta final ¿Qué modelo cambia la decisión operativa manteniendo explicación, estabilidad y costo bajo control?

Benchmark ilustrativo: desempeño y operación

Valores ficticios para aprender a comparar. El proyecto debe medirlos con el mismo protocolo.

Modelo	ROC-AUC	PR-AUC	Brier	Valor neto	Latencia	Explicación
Logística	0.76	0.31	0.18	base	baja	alta
Árbol podado	0.73	0.29	0.21	medio	muy baja	muy alta
Random Forest	0.82	0.38	0.16	alto	media	media
Boosting	0.84	0.41	0.15	muy alto	media-alta	media

La selección defendible aparece cuando la mejora técnica también sobrevive al análisis económico y operativo.

Después del despliegue: el problema sigue moviéndose

Un modelo correcto hoy puede degradarse si cambia la población, el canal, la prevalencia o el comportamiento del negocio.

01

Drift de datos

cambian distribuciones X

02

Concept drift

cambia $P(y|X)$

03

Cambio de prevalencia

cambia $P(y)$

04

Calibración

probabilidades se desalinean

Indicadores mínimos PSI / KS, métricas por período, calibración, costo real, volumen de acciones y alertas de cambio.

Interpretación no es solo técnica: también es gobernanza

En decisiones sensibles, desempeño agregado puede ocultar diferencias por segmento.

Preguntas de control

- ¿El error se concentra en un grupo?
- ¿La explicación usa proxies sensibles?
- ¿El threshold es consistente con política aprobada?
- ¿Existe circuito de revisión humana?

Qué reportar

Métricas globales y por segmento.
Costos de FP/FN explícitos.
Variables críticas e importancia estable.
Limitaciones y plan de monitoreo.

Formato de cierre: una decisión defendible

El entregable debe permitir que otro revise, cuestione y reproduzca la recomendación.

1

Pregunta

población, horizonte y acción

2

Evidencia

validación, métricas, estabilidad

3

Comparación

baseline, árbol, RF, boosting

4

Interpretación

variables, efectos y límites

5

Decisión

acción, costo, responsable, monitoreo

Una buena presentación de resultados hace visibles tanto las razones para actuar como las razones para ser prudente.

Laboratorio de interpretación, boosting y decisión

Simulaciones 12-16 para estudiar explicación y decisión. Monitoreo como extensión del proyecto.

SIM 15

Boosting

learning rate $\times$ árboles $\times$ overfitting

SIM 16

Decision Lab

valor, threshold, latencia y explicación

SIM 12

Importancias

MDI vs permutation importance

SIM 13

Correlación

variables redundantes y ranking engañoso

SIM 14

PDP/ICE

efecto promedio vs heterogeneidad

EXTENSIÓN

Monitoreo

drift, calibración y costo real

Síntesis conceptual

Boosting es potente, pero su uso profesional exige control de complejidad e interpretación honesta.

01

Secuencia

cada árbol corrige errores del modelo acumulado

02

Regularización

learning rate, profundidad y early stopping gobiernan generalización

03

Interpretación

importance, PDP, ICE y SHAP explican modelos, no causalidad

04

Decisión

el mejor modelo es el que mejora valor bajo restricciones reales

Puente al trabajo aplicado

La comparación final debe ser reproducible y orientada a una decisión concreta.

Entregable sugerido

Árbol podado, RF y boosting bajo el mismo protocolo.
Curvas train/validación y explicación de tuning.
Permutation importance fuera de muestra.
PDP/ICE o SHAP para un caso relevante.
Recomendación con costo, latencia y monitoreo.

No entregar

“El modelo ganó porque tuvo más AUC”.
Ranking de variables sin advertir sesgos.
Resultados de test usados para tuning.
Conclusiones causales no justificadas.

Boosting, explicación y decisión

Boosting puede ganar desempeño, pero el valor aparece cuando se lo valida, interpreta, calibra, monitorea y traduce a acción.



Próximo paso: experimentar en las simulaciones y defender la comparación final en Python.